

Глубинное обучение для текстовых данных (NLP)

Информация по курсу

Формула оценки:

Итог = Округление($0.3 * ДЗ + 0.4 * КР + 0.3 * Э$)

- 6 домашних заданий
- Контрольная работа (письменная) пройдет в середине семестра
- Экзамен устный
- **Автомат:** оценка ≥ 8 **до** округления

Ссылки:

Чат в тг: <https://t.me/+rbY-Zoy53p03MTEy>

GitHub: <https://github.com/ashaba1in/hse-nlp>

Про домашки

Все дз будут требовать написания кода и отчета к нему

Оформление:

- Строгих правил нет
- Но лучше оформлять в виде проекта
 1. Проще не запутаться в коде, когда его становится много
 2. Нам проще проверять структурированные домашки
 3. Проект можно выложить на гит и хвастаться им

Отчет:

- PDF документ с описанием проделанной работы
- Нужен *нам* для упрощения проверки
- Нужен *вам* для умения рассказывать о работе

План курса

1. Классификация и генерация текста
2. Трансформеры
3. BERT и GPT
4. Современные архитектуры трансформеров
5. Instruction tuning, Reasoning
6. Пайплайн обучения LLM: pre-training, mid-training, post-training
7. Retrieval-Augmented Generation
8. Parameter-Efficient Fine-Tuning, Model steering
9. Квантизация, дистилляция, спекулятивный декодинг
10. AI Interpretability and Safety
11. Текстовые диффузионные модели
12. Мультимодальные модели

Классификация текста

Виды задачи классификации

Бинарная классификация

- Сообщение спам или не спам?

Многоклассовая (multi-class) классификация

- Насколько срочно надо дать ответ клиенту?

Многоклассовая классификация с пересекающимися классами (multi-label classification)

- Какая тематика у новости?

Классификация слов

- Распознавание именованных сущностей (NER)
- Генерация текста

Виды задачи классификации

Бинарная классификация

- Сообщение спам или не спам?

Многоклассовая (multi-class) классификация

- Насколько срочно надо дать ответ клиенту?

Многоклассовая классификация с пересекающимися классами (multi-label classification)

- Какая тематика у новости?

Классификация слов


- Распознавание именованных сущностей (NER)
- Генерация текста

Все задачи в NLP –
задачи классификации

Датасеты для классификации

Название	Задача	Таргет	Размер	Средняя длина	Метрика
SST	тональность	5 или 2	11,855	19	Accuracy
Yelp	тональность	5 или 2	280,000	179	Accuracy
IMDb	тональность	2	50,000	271	Accuracy
QQP	перепаразирование	2	404,291	22	F1 / Accuracy
CoLA	грамматичность	2	10,657	9	Matthew's Corr
AG News	тема	4	120,000	44	Accuracy
Yahoo! Answers	тема	10	1,400,000	131	Accuracy
DBpedia	тема	14	560,000	67	Accuracy

Общая схема решения



Задача NLP – извлечение признаков

Краткая история NLP

Год	Метод	Улучшение
1957	distributional hypothesis (J.R. Firth)	—
1972	TF-IDF	Ранжирование по релевантности
1990	Latent semantic analysis (LSA)	Семантическая близость
2003	Latent Dirichlet allocation (LDA)	Тематическое моделирование
2013	word2vec	Векторное представление слов
2016	fastText	Быстрая классификация текста Борьба с out-of-vocabulary
2018	contextual representations	Омонимия, порядок слов

Представление текста

Текст всегда представляется в виде последовательности простых сущностей (слов/токенов)

~~$x = \text{"В лесу родилась елочка"}$~~

$x = [\text{"В"}, \text{"лесу"}, \text{"родилась"}, \text{"елочка"}]$

Наивный Байес


$$y = \arg \max p(y | x) = \arg \max \frac{p(x | y) \cdot p(y)}{p(x)} = \arg \max p(x | y)p(y)$$

Наивный Байес

$$y = \arg \max p(y | x) = \arg \max \frac{p(x | y) \cdot p(y)}{p(x)} = \arg \max p(x | y)p(y)$$

$$p(x | y) = \prod_{i=1}^n p(x_i | y)$$

Условная
вероятность текста




$$p(x_i | y = k) = \frac{N(x_i, y = k)}{\sum_{j=1}^{|V|} N(x_j, y = k)}$$

Встречаемость
слова




Условная
вероятность слова



$$p(y = k) = \frac{1}{N} \sum_{i=1}^N [y_i = k]$$

Вероятность ответа



Наивный Байес

$$y = \arg \max p(y | x) = \arg \max \frac{p(x | y) \cdot p(y)}{p(x)} = \arg \max p(x | y)p(y)$$

$$p(x | y) = \prod_{i=1}^n p(x_i | y)$$

Условная
вероятность текста

$$p(x_i | y = k) = \frac{N(x_i, y = k)}{\sum_{j=1}^{|V|} N(x_j, y = k)}$$

Встречаемость
слова

Условная
вероятность слова

$$p(y = k) = \frac{1}{N} \sum_{i=1}^N [y_i = k]$$

Вероятность ответа

Какие у него недостатки?

TF-IDF + Логистическая регрессия

TF-IDF

$$\text{tf}(t, d) = \frac{1}{N_d} \sum_{i=1}^{N_d} [t = d_i]$$

$$\text{idf}(t, D) = \log \frac{|D|}{\sum_{d \in D} [t \in d]}$$

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

TF-IDF + Логистическая регрессия

TF-IDF

$$\text{tf}(t, d) = \frac{1}{N_d} \sum_{i=1}^{N_d} [t = d_i]$$

$$\text{idf}(t, D) = \log \frac{|D|}{\sum_{d \in D} [t \in d]}$$

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$\text{text} = [\text{"В"}, \text{"лесу"}, \text{"родилась"}, \text{"елочка"}]$

$$x = \{\text{tf-idf}\}_{t \in \text{text}}$$

Логистическая регрессия

$$p_y = \text{softmax}(Wx + b)_y$$

W, b – обучаемые параметры

$$L(W, b) = - \sum_{i=1}^N \sum_{k=1}^K [y = k] \cdot \log p_k$$

TF-IDF + Логистическая регрессия

TF-IDF

$$\text{tf}(t, d) = \frac{1}{N_d} \sum_{i=1}^{N_d} [t = d_i]$$

$$\text{idf}(t, D) = \log \frac{|D|}{\sum_{d \in D} [t \in d]}$$

$$\text{tf-idf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

Какие тут недостатки?

$\text{text} = [\text{"В"}, \text{"лесу"}, \text{"родилась"}, \text{"елочка"}]$

$$x = \{\text{tf-idf}\}_{t \in \text{text}}$$


Логистическая регрессия

$$p_y = \text{softmax}(Wx + b)_y$$


W, b – обучаемые параметры

$$L(W, b) = - \sum_{i=1}^N \sum_{k=1}^K [y = k] \cdot \log p_k$$

Линейный слой




Линейный слой



Линейный слой

Векторы линейного слоя для каждого класса должны коррелировать с векторными представлениями элементов класса.

Скалярное произведение векторов **максимально**, когда они **сонаправлены**.



Минусы подходов

- Не учитывают связь между словами
- Не учитывают порядок слов

$p(y = + \mid \text{это не хорошо, совсем плохо})$

||

$p(y = + \mid \text{это хорошо, совсем не плохо})$

- Признаки извлекаются вручную


Плюсы подходов

- Достаточно хорошо справляются с большинством задач
- Скорость работы
- Время обучения
- Интерпретируемость

Интерпретируемость очень важна, когда цена ошибки велика


- Постановка медицинского диагноза
- Вынесение приговора в суде

Нейросетевые модели



Bag of Embeddings


Представляем текст в
виде суммы эмбеддингов



Bag of Embeddings

Представляем текст в виде суммы эмбеддингов


- + Очень легко реализовать
- Не учитываем связь между словами
- Нейтральные слова могут перетянуть вес на себя



Weighted Bag of Embeddings

- Домножаем эмбединги на веса TF-IDF
- После этого складываем

- + Все еще легко реализовать
- + У менее важных слов будет меньший вес
- Не учитываем связь между словами



Генерация текста

Зачем это нужно?

Автодополнение слова

В лесу родилась елочка

Автодополнение фразы

Почему птицы летают
поют
летят клином

Диалоговые системы

– Какая погода в Москве?

В Москве сейчас 8 градусов –

Постановка задачи

Текст должен удовлетворять требованиям:

- Логическая связность
- Соблюдение языковых норм

Можно попытаться задать правила вручную.

Но правил слишком много, поэтому ничего хорошего не выйдет.

Постановка задачи

Будем учиться имитировать человеческую речь

Для этого необходимо уметь оценивать вероятность текстов

$$p(\text{"В лесу родилась елочка"}) = p(\text{"В"}, \text{"лесу"}, \text{"родилась"}, \text{"елочка"})$$

Постановка задачи

Будем учиться имитировать человеческую речь

Для этого необходимо уметь оценивать вероятность текстов

$$p(\text{"В лесу родилась елочка"}) = p(\text{"В", "лесу", "родилась", "елочка"}) = ???$$

Постановка задачи

Будем учиться имитировать человеческую речь

Для этого необходимо уметь оценивать вероятность текстов

$$p(\text{"В лесу родилась елочка"}) = p(\text{"В"}, \text{"лесу"}, \text{"родилась"}, \text{"елочка"}) = ???$$

Можно использовать chain rule и генерировать текст по слову

$$p(x_1, \dots, x_m) = \prod_{i=1}^m p(x_i | x_{<i})$$

Как оценить $p(x_i | x_{<i})$?

Из наивного Байеса


$$p(x_i | y = k) = \frac{N(x_i, y = k)}{\sum_{j=1}^{|V|} N(x_j, y = k)}$$

Как оценить $p(x_i | x_{<i})$?

Из наивного Байеса

$$p(x_i | y = k) = \frac{N(x_i, y = k)}{\sum_{j=1}^{|V|} N(x_j, y = k)}$$

Произвольная
длина условия




Как оценить $p(x_i | x_{<i})$?

Из наивного Байеса

$$p(x_i | y = k) = \frac{N(x_i, y = k)}{\sum_{j=1}^{|V|} N(x_j, y = k)}$$

Произвольная
длина условия



Упростим задачу – будем смотреть только на предыдущие n слов.

$$p(x_1, \dots, x_m) \approx \prod_{i=1}^m p(x_i | x_{i-1}, \dots, x_{i-n})$$

Такая модель называется n -граммной.

N-грамм модель генерации

Предполагаем, что следующее слово зависит только от n предыдущих

$$p(x_1, \dots, x_m) \approx \prod_{i=1}^m p(x_i | x_{i-1}, \dots, x_{i-n})$$

Если у слова меньше, чем n предыдущих, дополним пропуски символом <PAD>.

$$\begin{aligned} p(\text{В}, \text{лесу}, \text{родилась}, \text{елочка}) = & \\ & p(\text{В} \mid \text{<PAD>}, \text{<PAD>}) \\ & \cdot p(\text{лесу} \mid \text{<PAD>}, \text{В}) \\ & \cdot p(\text{родилась} \mid \text{В}, \text{лесу}) \\ & \cdot p(\text{елочка} \mid \text{лесу}, \text{родилась}) \end{aligned}$$

N-грамм модель генерации: обучение

- Нужно оценить вероятность $p(x_i | x_{i-1}, \dots, x_{i-n})$.
- Посчитаем вручную, сколько раз x_i встретилось после $x_{i-1}, \dots, x_{i-n}$.

$$p(x_i | x_{i-1}, \dots, x_{i-n}) = \frac{p(x_i, x_{i-1}, \dots, x_{i-n})}{p(x_{i-1}, \dots, x_{i-n})} = \frac{N(x_i, x_{i-1}, \dots, x_{i-n})}{N(x_{i-1}, \dots, x_{i-n})}$$

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

<PAD> <PAD> _

$$p(\text{В} \mid \text{<PAD> <PAD>}) = 0.3$$

$$p(\text{Я} \mid \text{<PAD> <PAD>}) = 0.2$$

$$p(\text{Из} \mid \text{<PAD> <PAD>}) = 0.15$$

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

<PAD> <PAD> B _

$$p(\text{доме} \mid \text{<PAD> B}) = 0.34$$

$$p(\text{лесу} \mid \text{<PAD> B}) = 0.23$$

$$p(\text{машине} \mid \text{<PAD> B}) = 0.09$$

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

<PAD> <PAD> В лесу _

$$p(\text{было} \mid \text{В лесу}) = 0.4$$

$$p(\text{воют} \mid \text{В лесу}) = 0.23$$

$$p(\text{родилась} \mid \text{В лесу}) = 0.09$$

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

<PAD> <PAD> В лесу было _

$$p(\text{темно} \mid \text{лесу было}) = 0.22$$

$$p(\text{холодно} \mid \text{лесу было}) = 0.2$$

$$p(\text{свежо} \mid \text{лесу было}) = 0.13$$

N-грамм модель генерации: генерация

Генерируем слова по одному в соответствии с вероятностями.

<PAD> <PAD> В лесу было темно

Преимущества n-грамм

Преимущества n-грамм

- Тексты состоят из существующих n-грамм.
- Поэтому предложения грамматически верные.
- Модель проста в реализации и очень быстрая.


Недостатки n-грамм

Недостатки n -грамм

- При генерации смотрит только на последние n слов.
- Из-за этого получаются логически несвязные тексты.
- При увеличении n вероятности слов оцениваются хуже.


Рекуррентные нейронные сети (RNN)

Нейронные сети для генерации текста




Recurrent neural networks (RNN)

- Разработаны для работы с последовательными данными.
- Каждый блок предсказывает следующий токен.




Recurrent neural networks (RNN)

- Разработаны для работы с последовательными данными.
- Каждый блок предсказывает следующий токен.
- Процесс генерации интуитивно понятен.




Recurrent neural networks (RNN)

- Разработаны для работы с последовательными данными.
- Каждый блок предсказывает следующий токен.




Блок RNN



$$h_t = \sigma(Wx_{t-1} + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



RNN: Обучение

$$p(x_1, \dots, x_m) = \prod_{t=1}^m p(x_t | x_{<t}) \rightarrow \max$$

$$p(\cdot | x_{<t}) = \text{softmax}(o_t)$$




RNN: Обучение

$$p(x_1, \dots, x_m) = \prod_{t=1}^m p(x_t | x_{<t}) \rightarrow \max$$

$$p(\cdot | x_{<t}) = \text{softmax}(o_t)$$


Функция ошибки

$$L(X) = -\frac{1}{|X|} \sum_{x \in X} \sum_{t=1}^m \log p(x_t | x_{<t})$$



Градиенты RNN


$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$



Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$




Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$




Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$




Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$



Посмотрим на то, как ведут себя градиенты.
Будет немного больно.

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$

chain rule

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

$$\frac{dh_t}{dU} = \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{dh_{t-1}}{dU}$$

Переходим от производных к частным производным

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

$$\begin{aligned} \frac{dh_t}{dU} &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \boxed{\frac{dh_{t-1}}{dU}} = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \boxed{\left(\frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} \right)} \end{aligned}$$

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

$$\begin{aligned} \frac{dh_t}{dU} &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{dh_{t-1}}{dU} = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \left(\frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} \right) = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} \end{aligned}$$

Раскрываем скобки

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$

$$L = \sum_{t=1}^m L_t$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

$$\begin{aligned} \frac{dh_t}{dU} &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{dh_{t-1}}{dU} = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \left(\frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} \right) = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} = \\ &= \sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \end{aligned}$$

Собираем все в одну сумму

Градиенты RNN

$$h_t = \sigma(Wx_t + Uh_{t-1} + b_h)$$

$$o_t = Oh_t + b_o$$

$$L_t = -\log p(x_t | x_{<t}) = -\log \text{softmax}(o_t)_{x_t}$$


$$L = \sum_{t=1}^m L_t$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \frac{dh_t}{dU}$$

$$\begin{aligned} \frac{dh_t}{dU} &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{dh_{t-1}}{dU} = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \left(\frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} \right) = \\ &= \frac{\partial h_t}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial U} + \frac{\partial h_t}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial h_{t-2}} \frac{dh_{t-2}}{dU} = \\ &= \sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \end{aligned}$$

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right]$$

Взрыв градиентов

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right]$$


Серия умножений производных

$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| > 1$$

- Происходит **взрыв градиента** $\frac{dL}{dU}$
- Модель расходится, NaN в весах

Взрыв градиентов

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right]$$

Серия умножений производных

$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| > 1$$

- Происходит **взрыв градиента** $\frac{dL}{dU}$
- Модель расходится, NaN в весах

Решения:

- Регуляризация
- Уменьшение learning rate
- Gradient clipping

Взрыв градиентов

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right]$$

Серия умножений производных

$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| > 1$$

- Происходит **взрыв градиента** $\frac{dL}{dU}$
- Модель расходится, NaN в весах

Решения:

- Регуляризация
- Уменьшение learning rate
- Gradient clipping

$$1. g \leftarrow \min \left(1, \frac{\text{max norm}}{\|g\|} \right) \cdot g$$

Правильный способ

$$2. g \leftarrow \text{clip}(g, -C, C)$$

Ленивый способ (меняет направление градиента)

Затухание градиентов

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right]$$
$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| < 1$$

- Происходит **затухание градиента**
- Модель перестает учиться
- Модель не улавливает далекие зависимости!

Затухание градиентов

$$\frac{dL}{dU} = \sum_{t=1}^m \frac{dL_t}{do_t} \frac{do_t}{dh_t} \left[\sum_{k=1}^t \left(\prod_{j=k+1}^t \frac{\partial h_j}{\partial h_{j-1}} \right) \frac{\partial h_k}{\partial U} \right] \quad \left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| < 1$$

- Происходит **затухание градиента**
- Модель перестает учиться
- Модель не улавливает далекие зависимости!

Затухание градиентов – частая проблема RNN.

Ее нельзя починить трюками.

Затухание градиентов: почему возникает?


$$h_j = \sigma(\underbrace{Wx_j + Uh_{j-1} + b_h}_{z_j})$$

$$\frac{\partial h_j}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial z_j} \frac{\partial z_j}{\partial h_{j-1}}$$

Затухание градиентов: почему возникает?

$$h_j = \sigma(\underbrace{Wx_j + Uh_{j-1} + b_h}_{z_j})$$

Поэлементное умножение

$$\frac{\partial h_j}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial z_j} \frac{\partial z_j}{\partial h_{j-1}} = \left(\sigma(z_j) \odot (1 - \sigma(z_j)) \right) U$$


Затухание градиентов: почему возникает?

$$h_j = \sigma(\underbrace{Wx_j + Uh_{j-1} + b_h}_{z_j})$$

Поэлементное умножение

$$\frac{\partial h_j}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial z_j} \frac{\partial z_j}{\partial h_{j-1}} = \left(\sigma(z_j) \odot (1 - \sigma(z_j)) \right) U$$

Посмотрим на спектральную норму

$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| \leq \underbrace{\| \sigma(z_j) \odot (1 - \sigma(z_j)) \|}_{< 1} \cdot \|U\|$$

т. к. $\sigma(z) \in [0, 1]$

Затухание градиентов: почему возникает?

$$h_j = \sigma(\underbrace{Wx_j + Uh_{j-1} + b_h}_{z_j})$$

Поэлементное умножение

$$\frac{\partial h_j}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial h_{j-1}} = \frac{\partial \sigma(z_j)}{\partial z_j} \frac{\partial z_j}{\partial h_{j-1}} = \left(\sigma(z_j) \odot (1 - \sigma(z_j)) \right) U$$

Посмотрим на спектральную норму

$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| \leq \underbrace{\| \sigma(z_j) \odot (1 - \sigma(z_j)) \|}_{< 1} \cdot \|U\|$$

т. к. $\sigma(z) \in [0, 1]$

Если U – ортогональная, то


$$\left\| \frac{\partial h_j}{\partial h_{j-1}} \right\| \leq \| \sigma(z_j) \odot (1 - \sigma(z_j)) \| < 1$$

RNN для классификации

- В качестве предсказания берем выход **последнего** блока.



Классификация тональности

- 1** – ПОЗИТИВНЫЙ
- 0** – НЕГАТИВНЫЙ




Long shot-term memory (LSTM)

В LSTM добавляется вектор памяти c_t
Благодаря ему модель не забывает старую информацию



LSTM: фильтр забывания

Контролирует, какую информацию надо забыть, а какую оставить.




$$f_t = \sigma(W_f x_{t-1} + U_f h_{t-1} + b_f)$$

$$f_t \in [0,1]$$

LSTM: фильтр забывания

Контролирует, какую информацию надо забыть, а какую оставить.



$$f_t = \sigma(W_f x_{t-1} + U_f h_{t-1} + b_f)$$

$$f_t \in [0, 1]$$


Еда была **вкусная** и мы **не разочаровались**.

x_3 – слово-маркер, можно забыть все до него.

x_7 – негативный маркер, но до него идет "**не**".
Знаем об этом из h_7 .

LSTM: фильтр входа

Контролирует, какую информацию надо добавить в вектор памяти C_t



Из-за i_t можем не добавлять ничего.


$$i_t = \sigma(W_i x_{t-1} + U_i h_{t-1} + b_i)$$

$$i_t \in [0, 1]$$

$$\tilde{C}_t = \tanh(W_i x_{t-1} + U_i h_{t-1} + b_i)$$

LSTM: фильтр входа

Контролирует, какую информацию надо добавить в вектор памяти C_t



Из-за i_t можем не добавлять ничего.

$$i_t = \sigma(W_i x_{t-1} + U_i h_{t-1} + b_i)$$

$$i_t \in [0, 1]$$

$$\tilde{C}_t = \tanh(W_i x_{t-1} + U_i h_{t-1} + b_i)$$


Еда была **вкусная** и **мы** не разочаровались.

x_3 – слово-маркер.
Запоминаем, что класс
положительный.

x_5 – не влияет на класс.
Ничего не добавляем.

LSTM: обновление памяти


Удаляем ненужную информацию и добавляем новую.



$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

LSTM: фильтр выхода

Контролирует выход текущего шага.




$$o_t = \sigma(W_t x_{t-1} + U_t h_{t-1} + b_t)$$

$$h_t = o_t \odot \tanh(c_t)$$

LSTM: фильтр выхода

Контролирует выход текущего шага.



$$o_t = \sigma(W_t x_{t-1} + U_t h_{t-1} + b_t)$$

$$h_t = o_t \odot \tanh(c_t)$$

Учитель ведет урок, посвященный рекуррентным моделям. _

Начало нового предложения.
Надо вспомнить, что речь идет об учителе и уроке.

Самое важное

Классификация

- Классификация текста/слов – самая популярная задача в NLP
- Очень часто простые методы хорошо справляются
- Качество напрямую зависит от того, насколько хорошие признаки удалось извлечь

Генерация текста

- Классификация с огромным числом классов
- Значительно сложнее, так как требует более точного понимания текста
- Простые модели никогда не справляются