


BERT и GPT

План

- **BERT**
 - И его модификации
- **GPT**
 - И почему она так хороша
- Трюки для обучения трансформерных моделей


Трансформер

- Модель для **Seq2seq**, состоящая из **Encoder** и **Decoder**
- **Encoder** извлекает информацию из текста
- **Decoder** генерирует новый текст на основе этой информации
- Хорошо работает благодаря механизму **ВНИМАНИЯ**




Трансформер

Можно ли адаптировать эту модель под другие виды задач?



Какие бывают задачи?


many-to-many
одинаковая длина



Классификация токенов:

- Named Entity Recognition
- Part-of-speech tagging


many-to-many
разная длина



Seq2seq:

- Машинный перевод
- Суммаризация
- Перенос стиля


many-to-one



- Классификация
- Регрессия


Какие бывают задачи?

many-to-many
одинаковая длина




- Классификация токенов:
- Named Entity Recognition
 - Part-of-speech tagging

many-to-many
разная длина



- Seq2seq:
- Машинный перевод
 - Суммаризация
 - Перенос стиля

many-to-one



- Классификация
- Регрессия


Не нужно генерировать текст
Можем взять отдельно **Encoder!**

Нужно генерировать текст

BERT (2018)

Bidirectional Encoder Representations

- Модель на основе **Encoder**'а Трансформера
- В основном используется для решения произвольных задач классификации
- Самое важное – способ обучения BERT



BERT: Мотивация

- Трансформерные модели могут быть огромными
- Базовый BERT содержит 110M параметров
- Для обучения такой модели требуется очень много данных
- В задачах классификации размеченных данных обычно недостаточно

BERT: Мотивация

- Трансформерные модели могут быть огромными
- Базовый BERT содержит 110M параметров
- Для обучения такой модели требуется очень много данных
- В задачах классификации размеченных данных обычно недостаточно

Предобучим модель понимать язык на **неразмеченных** данных!

BERT: Обучение

Для предобучения любой модели без разметки необходимо создать **искусственную** задачу

BERT предобучается одновременно решая две задачи:

- Masked Language Modelling (**MLM**)
- Next Sentence Prediction (**NSP**)

Masked Language Modelling (MLM)

Идея: Маскируем несколько случайных токенов и просим модель их восстановить. Модель учится понимать, что значат слова и как они связаны между собой.


Алгоритм обучения:

- Случайно выбираем 15% токенов. Из них
 - 80% маскируем
 - 10% заменяем случайными токенами (чтобы модель не переобучалась под [MASK])
 - 10% оставляем без изменений (чтобы модель не считала все токены неправильными)
- Считаем ошибку для всех выбранных токенов

Masked Language Modelling (MLM)

Алгоритм обучения:

- Случайно выбираем 15% токенов. Из них
 - 80% маскируем
 - 10% заменяем случайными токенами
 - 10% оставляем без изменений
- Считаем ошибку для всех выбранных токенов




Next Sentence Prediction (NSP)

Идея: Хотим научить модель извлекать информацию из текста целиком. Полезно для классификации текста.


- Подаем в BERT два склеенных текста
- В половине случаев второй текст является продолжением первого, а в другой половине он случайный
- Добавляем [CLS] токен в начало и [SEP] в конец каждого текста
- Задача модели – по векторному представлению [CLS] предсказать, связаны ли тексты

Next Sentence Prediction (NSP)



Комбинация двух задач

BERT учится решать две задачи одновременно.



BERT: Результат

- Использование предобучения позволило обучить модель хорошо понимать текст.
- На момент создания BERT обгонял ближайшего конкурента на 7% на бенчмарке GLEU.

Датасеты (16 гб):


- BooksCorpus (800M слов)
- English Wikipedia (2500M слов)

Время обучения:

- 4 дня на 16 TPU

Как BERT извлекает признаки?

BERT на каждом слое извлекает все более сложные признаки с точки зрения лингвистики



Модификации BERT

Создание BERT стало революционным.

Появилась модель, которая хорошо решает ВСЕ задачи классификации.

Исследователи принялись изучать BERT и предлагать модификации.

Примеры:

- RoBERTa
- ALBERT
- DistilBERT
- DeBERTa
- ELECTRA

RoBERTa (2019)

Robustly optimized BERT approach

Оказалось, что BERT обучен очень неоптимально

RoBERTa учится

- Дольше (в 5 раз)
- На большем объеме данных (в 10 раз больше)
- С большим размером батча (8к токенов)
- С **динамическим** маскированием

Перед началом обучения BERT для каждого текста генерировалось 10 разных вариантов маскирования

RoBERTa маскирует текст случайно на каждой итерации

ALBERT (2019)

A Little BERT

- С увеличением размера модели качество растёт
- Однако так же растёт сложность вычислений и затраты по памяти
- Можем уменьшить число параметров двумя трюками:
 - Факторизуем матрицу эмбеддингов, так как она очень большая
 - Будем делить одни параметры между несколькими слоями (**parameter sharing**)
- Задача NSP заменяется на Sentence Order Prediction (SOP). Два предложения из одного текста идут либо в правильном порядке, либо в обратном

ALBERT: Факторизация матрицы

- Матрица эмбедингов E имеет размер $|V| \times D$, где $|V|$ – размер словаря, а D – размер скрытого пространства.
- Чтобы уменьшить число параметров, приблизим E произведением двух матриц $E = \underbrace{A}_{|V| \times H} \times \underbrace{B}_{H \times D}$
- При этом $H < D$ (низкоранговое приближение)


ALBERT: Parameter sharing

- Оказывается, что если применить один и тот же слой несколько раз, информации извлечется больше, чем когда он применяется один раз
- Используем эту идею и разделим одни параметры между всем слоями модели
- Если в модели L слоев, то затраты по памяти уменьшатся в L раз
- Удалось уменьшить число параметров в 10 раз без потери в качестве

GPT (2018)

Generative Pre-Training

- Вторая модель на основе Трансформера, способная предобучаться
- Применяется для **генерации** текста
- Использует **декодер** Трансформера без Cross Attention



GPT: Обучение

- GPT учится **языковому моделированию** (безусловная генерация текста)
- Благодаря способности Трансформера масштабироваться, GPT запоминает очень много информации в процессе обучения
- Любую задачу NLP можно свести к **генерации текста**
Классификация – генерация индекса класса
- Из-за этого GPT отлично дообучается на частные задачи

	Параметры	Данные
GPT-1	117M	5 гб
GPT-2	1.5B	40 гб
GPT-3	175B	45 тб

GPT обучается решать разные задачи

Задача	Пример текста, обучающий этой задаче
Грамматика	В свободное время я люблю (читать, табуретка)
Лексическая семантика	Я пошел в магазин, чтобы купить молоко и (яблоки, енота)
Знания о мире	Столица Франции – (Париж, Вена)
Классификация тональности	Я в восторге от декораций и игры актеров, спектакль был (хорошим, плохим)
Перевод	"Стол" по-английски будет ("table", "apple")
Пространственное мышление	Леша сидел на диване в гостиной, рядом с ним сидел Саша. Потом Саша встал и вышел из (гостиной, кухни)
Математика	Если прибавить 4 к 3, то будет (7, 8)

Zero-shot и Few-shot для GPT

Модель училась только предсказывать следующее слово, однако ее можно применять для новых задач

Zero-shot режим:

Переведи с русского на английский:
дом =>

Few-shot режим

Переведи с русского на английский:
стол => table
сыр => cheese
дом =>

Качество такого подхода не очень высокое.

Бенчмарки для LLM

MMLU (Massive Multitask Language Understanding)

Вопросы из разных областей с 4-мя вариантами ответа

Question: John Doe is a software engineer working for a company that develops autonomous weapons. He has serious ethical concerns about the potential misuse of this technology, which could lead to civilian casualties. However, he also has a family to support and fears losing his job if he speaks out. What is the primary ethical conflict John is facing?


A) Conflict of interest

B) Whistleblower's dilemma

C) Professional negligence

D) Intellectual property rights

Answer: B



Бенчмарки для LLM

- Коллекция датасетов, на которых можно "легко" проверить ответ
- Обычно это ответы на вопросы

Варианты тестирования:

- Вероятность правильного ответа
- Доля правильных ответов

Scenario	Task	What	Who
NarrativeQA	short-answer question answering	passages are books and movie scripts, questions are unknown	annotators from summaries
NaturalQuestions (closed-book)	short-answer question answering	passages from Wikipedia, questions from search queries	web users
NaturalQuestions (open-book)	short-answer question answering	passages from Wikipedia, questions from search queries	web users
OpenbookQA	multiple-choice question answering	elementary science	Amazon Mechanical Turk workers
MMLU	multiple-choice question answering	math, science, history, etc.	various online sources
GSM8K (Grade School Math)	numeric answer question answering	grade school math word problems	contractors on Upwork
MATH	numeric answer question answering	math competitions (AMC, AIME, etc.)	problem setters
LegalBench	multiple-choice question answering	public legal and administrative documents, manually	lawyers
MedQA	multiple-choice question answering	US medical licensing exams	problem setters
WMT 2014	machine translation	multilingual sentences	Europarl, news, Common Crawl, etc.

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)

Данные

- Л
- П
- Р

```
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Transitional//EN" "http://www.w3.org/TR/xhtml1/DTD/xhtml1-transitional.dtd"
xmlns="http://www.w3.org/1999/xhtml"> <head> <meta http-equiv="Content-Type" content="text/html; charset=utf-8" /> <title>000 084
Downloads Free 000 084 - Download 000 084 Software</title> <meta type="description" content="000 084 at Smart Code for free download. 000
084 freeware and shareware free downloads." /> <meta type="keywords" content="000 084, downloads, freeware, software, free, 000-084 Test
Prep Training, Pass4sure IBM 000-084, TopCerts 000-084 Questions and Answers, HP0-084 Free Practice Exam Questions, Pass4sure ADOBE
9A0-084" /> <link rel="shortcut icon" href="/design/favicon.ico" type="image/x-icon" /> <link href="/design/look.css" rel="stylesheet"
type="text/css" /> <!--[if lt= 6]> <link href="/design/ieexplorer6.css" rel="stylesheet" type="text/css" /> <![endif]--> <script
type="text/javascript">link = "http://www.smartcode.com";</script> <script type="text/javascript" src="/design/bmark.js"></script> <link
href="/design/generic/ui.css" rel="stylesheet" type="text/css" /> <script src="/cms/generic.2/scripts/jquery.js" type="text/javascript"
language="javascript"></script> <script src="/cms/generic.2/scripts/ui.js" type="text/javascript" language="javascript"></script> </head>
<body> <div id="wrapper"> <div id="header"> <a class="logo_type" href="http://www.smartcode.com/"><!----></a> </div> <div id="menu"> <script type="text/javascript"
src="/design/jcoding.js"></script> <form action="http://www.smartcode.com/downloads" id="search" name="search" method="get"
onsubmit="return do_search(false);"> <input class="inp_text" type="text" name="query" id="query" value="" /> <a href="#" onclick="do_search
(false);return false;" class="input_href"></a> </form> <ul> <li><a
href="http://www.smartcode.com/">Home</a></li> <li><a href="http://www.smartcode.com/db/allrootandsubcate.php">Categories</a></li> <li><a
href="http://www.smartcode.com/db/new.php">New</a></li> <li><a href="http://www.smartcode.com/db/top.php">Popular</a></li> <li><a
href="http://www.smartcode.com/submit/">Submit</a></li> <li><a href="http://www.smartcode.com/main/rss/">RSS</a></li> <li><a
href="http://www.smartcode.com/main/contact.html">Contact</a></li> </ul> </div> <div id="content"> <div id="content_right"> <style> h1 {
padding-bottom: 15px; } h1 strong { float: left; } div.pager { font-size: 11px; float: right; padding-top: 5px; } </style> <div
style="display:none;"> <false><br> <br> <br> <br> </div> <table border="0" cellpadding="0" cellspacing="0" id="table1"> <tr> <td
width="4">&nbsp;</td> <td> <script src="/design/ccoding.js" type="text/javascript"></script> </td> <td width="15">&nbsp;</td> <td> <script
src="/design/ccoding_im.js" type="text/javascript"></script> </td> </tr> </table> <br> <div class="hr" style="width:100%;
margin-bottom:10px;"></div> <h1> <strong>000 084</strong> <div class="pager"> Pages:&nbsp;  1 <a href="/p2.html"> 2 </a> <a href="/p3
.html"> 3 </a> &nbsp; <a href="http://000-084.smartcode.com/freeware.html">Freeware</a>&nbsp; <a href="http://000-084.smartcode.com/macosex
.html">Mac</a> </div> </h1> <br> <p ot="1=Testkingworld.com is your ultimate source for the System x High Performance Servers...">
Testkingworld.com is your ultimate source for the System x High Performance Servers...&nbsp;<a class="details-link"
href="http://000-084-test-prep-training.smartcode.com/info.html">Details</a></p><br> <p ot="1=One of the best and most rewarding features
of the 000-084 training materials are that..."> One of the best and most rewarding features of the 000-084 training materials are
that...&nbsp;<a class="details-link" href="http://pass4sure-ibm-000-084.smartcode.com/info.html">Details</a></p><br> <p ot="1=Download
free 000-084 questions and answers, 000-084 exam questions are ultimate..."> Download free 000-084 questions and answers, 000-084 exam
questions are ultimate...&nbsp;<a class="details-link" href="http://topcerts-000-084-questions-and-answers.smartcode.com/info
.html">Details</a></p><br> <p ot="1=Pass-Guaranteed is the leader in IT Certifications that offers a 100% Money Back..."> Pass-Guaranteed
is the leader in IT Certifications that offers a 100% Money Back...&nbsp;<a class="details-link"
```

Б)

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)
 2. Извлечение текста из HTML (сложности: математика, шаблоны)

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)
 2. Извлечение текста из HTML (сложности: математика, шаблоны)
 3. Фильтрация нежелательного контента
Например, NSFW, вредоносного контента, персональных данных

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)
 2. Извлечение текста из HTML (сложности: математика, шаблоны)
 3. Фильтрация нежелательного контента
Например, NSFW, вредоносного контента, персональных данных
 4. Дедупликация (url/документ/строка).
Например, все заголовки/нижние колонтитулы/меню на форумах всегда одинаковы.

Данные

- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)
 2. Извлечение текста из HTML (сложности: математика, шаблоны)
 3. Фильтрация нежелательного контента
Например, NSFW, вредоносного контента, персональных данных
 4. Дедупликация (url/документ/строка).
Например, все заголовки/нижние колонтитулы/меню на форумах всегда одинаковы.
 5. Эвристическая фильтрация. Отсеивание низкокачественных документов.
Например, количество слов, длина слова, выбросы, грязные фрагменты

Данные


- **Идея:** использовать весь чистый интернет
- **Проблема:** интернет — грязный и не отражает того, что нам нужно.
- **Как на самом деле:**
 1. Скачать весь интернет. Common Crawl: 250 миллиардов страниц, (> 1 ПБ)
 2. Извлечение текста из HTML (сложности: математика, шаблоны)
 3. Фильтрация нежелательного контента
Например, NSFW, вредоносного контента, персональных данных
 4. Дедупликация (url/документ/строка).
Например, все заголовки/нижние колонтитулы/меню на форумах всегда одинаковы.
 5. Эвристическая фильтрация. Отсеивание низкокачественных документов.
Например, количество слов, длина слова, выбросы, грязные фрагменты
 6. Фильтрация на основе модели. Предсказываем, может ли страница быть ссылкой из Википедии.

Трюки для обучения трансформеров

Warm-up


Постепенное увеличение скорости обучения на ранних шагах оптимизации.

График изменения Learning rate




Warm-up

- Трансформеры не обучаются без warm-up!
- Чем глубже Трансформер, тем нужнее warm-up
- Без warm-up градиенты начинают затухать



Размер батча

- Обычно с небольшим размером батча трансформер хуже учится
- Но не всегда!
- Размер батча зависит от размера модели



Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных

Из-за self-attention разные параметры получают разные по норме градиенты.

Adam настраивает шаг обучения для каждого параметра отдельно

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)

- Gradient clipping

Защищает от взрыва градиентов

- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляирование градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных



Полезно, если большой батч не
влезает в память

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных

Редко применяется, но
позволяет ускорить обучение

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных



Уменьшает затраты по памяти

Дополнительные трюки

- SGD работает гораздо хуже, чем Adam (AdamW, LAMB, AdaFactor, ...)
- Gradient clipping
- Аккумуляция градиентов
- Группировка текстов по длине в батчах
- Mixed-precision
- Очистка данных

Данные должны максимально соответствовать downstream задаче

Чистые данные избавлены от

- Жаргонных текстов
- Ложной информации
- Специальных символов разметки