

Transfer Learning

План

- Что такое Transfer Learning
- Способы дообучения моделей
- Parameter-Efficient Fine-tuning
 - Prompt-tuning
 - Adaptars
 - LoRa
 - BitFit

Большая модель для маленькой задачи




Большие модели могут выучить много информации
=> логично использовать их для всех задач



Большие модели требуют много данных для обучения
На маленьких задачах они переобучаются

[Как решить эту проблему?]



JAKE-CLARK.TUMBLR

Transfer learning

Transfer learning – перенос знаний обученной модели на новую задачу.



Обучение разбивается на две стадии:

- **Предобучение** – self-supervised обучение на куче данных
- **Дообучение** на небольшую *downstream* задачу

Модификации BERT и GPT

Классификация текста:



- У обеих моделей меняется последний линейный слой
- У BERT берется выход [CLS] токена
- У GPT – выход последнего токена



Модификации BERT и GPT


Классификация токенов:

- Так же меняется последний линейный слой
- Берутся выходы каждого токена
- Лучше использовать **BERT**




Способы дообучения

Обучение головы
(линейный пробинг)




Обучается только
последний слой

Fine-tuning



Обучается вся
модель

Parameter Efficient
Fine-tuning



Обучается
небольшой
набор весов

Пробинг vs Fine-tuning

Downstream задача – небольшая по объему данных задача, на которую дообучается модель (напр., классификация новостей).

Пробинг vs Fine-tuning

Downstream задача – небольшая по объему данных задача, на которую дообучается модель (напр., классификация новостей).

Пробинг

- Самый простой и быстрый способ дообучения
- Не меняем информацию, извлекаемую моделью

Fine-tuning

- Самый долгий, но эффективный способ
- Обучает модель извлекать важную для **downstream** задачи информацию

Сравнение с точки зрения ID и OOD

ID (In Distribution) – данные, лежащие в распределении **downstream** задачи (на чем обучаем)

- Новости издания Известия

OOD (Out Of Distribution) – данные, лежащие вне распределения **downstream** задачи (другие данные для задачи такого вида)

- Новости из Одноклассники.ru
- Новости Russia Today (RT)

Сравнение с точки зрения ID и OOD

ID (In Distribution) – данные, лежащие в распределении **downstream** задачи (на чем обучаем)

- Новости издания Известия

OOD (Out Of Distribution) – данные, лежащие вне распределения **downstream** задачи (другие данные для задачи такого вида)

- Новости из Одноклассники.ru
- Новости Russia Today (RT)


	Fine-tuning	Пробинг
ID test	85.1%	82.9%
OOD test	59.3%	66.2%

Точность классификации

Fine-tuning портит модель


Из-за случайной инициализации головы градиенты слишком сильно сдвигают веса модели на первых итерациях. Это приводит к переобучению.

Пробинг



Недостаточно близко подходим к оптимуму


Fine-tuning



Близко подходим к оптимуму, но сильно меняем исходные параметры модели

Пробинг → Fine-tuning

Обучим сначала голову, а затем дообучим веса всей модели с помощью fine-tuning.



Пробинг → Fine-tuning

Качество вырастает как на OOD, так и на ID.

	Fine-tuning	Пробинг	Пробинг → Fine-tuning
ID test	85.1%	82.9%	85.7%
OOD test	59.3%	66.2%	68.9%

Точность классификации

План

- Что такое Transfer Learning
- Способы дообучения моделей
- **Parameter-Efficient Fine-tuning**
 - Prompt-tuning
 - Adapters
 - LoRa

Parameter-Efficient Fine-tuning

- Способ дообучения моделей с изменением минимального числа параметров
- Используется для обучения LLM, которые слишком затратно обучать целиком
- При дообучении на несколько разных задач можно хранить только набор измененных параметров для каждой задачи

Few-shot и Zero-shot для GPT

- GPT-3 обучалась на 45 тб данных. Это дает ей интересные свойства.
- Модель можно применять для новой задачи, показав ей примеры решения в промпте.

Переведи с русского на английский:

стол => table

сыр => cheese

дом =>

Это называется **Few-shot** режим.


Переведи с русского на английский:

дом =>

Это называется **Zero-shot** режим.

Few-shot и Zero-shot для GPT

Чем больше модель, тем лучше она работает в таком режиме.




Однако результат может быть так себе из-за того, что

- Модель не училась решать эту задачу
- Промпт недостаточно хорош

Prompt Tuning

Идея: Попробуем автоматически подобрать наиболее подходящий промпт



- Инициализируем эмбединги промпта случайно, задавая только их число
- Можно инициализировать эмбедингами текстового промпта
- Для задачи классификации нужно дополнительно обучить голову



Prompt Tuning

- Длина промпта напрямую влияет на качество модели
- Однако чем больше модель, тем меньше разница в качестве

Длина промпта




Prompt Tuning: Недостатки

- Дополнение обучаемого промпта ограничивает максимальную длину и замедляет модель
- Prompt Tuning учится очень нестабильно и качество меняется немонотонно при увеличении размеров промпта и модели

Adapters

- После каждого слоя внимания и FFN добавляется **небольшой** обучаемый адаптер
- Адаптер имеет skip-connection и два полносвязный слоя с **понижением** размерности (уменьшает число параметров)
- Обучаются только адаптеры, нормализации и голова
- Такое дообучение по качеству достигает fine-tuning




Adapters: Недостатки

- Базовая версия адаптера добавляет довольно много параметров по сравнению с Prompt Tuning
- Адаптеры добавляют дополнительные слои, которые нельзя считать параллельно
- Это замедляет модель. Особенно для малых размеров батча.

Intrinsic Dimensionality of Language Models

Для дообучения требуется только незначительная часть параметров.




LoRA

Low-Rank Adaptation

- **Идея:** для адаптации модели к новой задаче нужно сдвинуть веса в сторону антиградиента

$$W' = W + \Delta W$$



LoRA


Low-Rank Adaptation

- **Идея:** для адаптации модели к новой задаче нужно сдвинуть веса в сторону антиградиента

$$W' = W + \Delta W$$

- Приблизим ΔW низкоранговым произведением обучаемых матриц AB

$$W' = W + AB$$



LoRA

Low-Rank Adaptation


- **Идея:** для адаптации модели к новой задаче нужно сдвинуть веса в сторону антиградиента

$$W' = W + \Delta W$$

- Приблизим ΔW низкоранговым произведением обучаемых матриц AB

$$W' = W + AB$$

- Так изменяются только матрицы W_q и W_v механизма внимания
- Добавляем очень мало параметров и добавка может считаться параллельно с основным блоком (или можно прибавить к параметрам)



BitFit

Bias-terms Fine-tuning

Идея: сдвиги имеют очень мало параметров, будем обучать только их

Attention

$$\mathbf{Q}^{m,\ell}(\mathbf{x}) = \mathbf{W}_q^{m,\ell} \mathbf{x} + \mathbf{b}_q^{m,\ell}$$

$$\mathbf{K}^{m,\ell}(\mathbf{x}) = \mathbf{W}_k^{m,\ell} \mathbf{x} + \mathbf{b}_k^{m,\ell}$$

$$\mathbf{V}^{m,\ell}(\mathbf{x}) = \mathbf{W}_v^{m,\ell} \mathbf{x} + \mathbf{b}_v^{m,\ell}$$

$$\mathbf{h}_1^\ell = att(\mathbf{Q}^{1,\ell}, \mathbf{K}^{1,\ell}, \mathbf{V}^{1,\ell}, \dots, \mathbf{Q}^{m,\ell}, \mathbf{K}^{m,\ell}, \mathbf{V}^{m,\ell})$$

Feed Forward Network

$$\mathbf{h}_2^\ell = \text{Dropout}(\mathbf{W}_{m_1}^\ell \cdot \mathbf{h}_1^\ell + \mathbf{b}_{m_1}^\ell)$$

$$\mathbf{h}_3^\ell = \mathbf{g}_{LN_1}^\ell \odot \frac{(\mathbf{h}_2^\ell + \mathbf{x}) - \mu}{\sigma} + \mathbf{b}_{LN_1}^\ell$$

$$\mathbf{h}_4^\ell = \text{GELU}(\mathbf{W}_{m_2}^\ell \cdot \mathbf{h}_3^\ell + \mathbf{b}_{m_2}^\ell)$$

$$\mathbf{h}_5^\ell = \text{Dropout}(\mathbf{W}_{m_3}^\ell \cdot \mathbf{h}_4^\ell + \mathbf{b}_{m_3}^\ell)$$


$$\text{out}^\ell = \mathbf{g}_{LN_2}^\ell \odot \frac{(\mathbf{h}_5^\ell + \mathbf{h}_3^\ell) - \mu}{\sigma} + \mathbf{b}_{LN_2}^\ell$$

Сравнение методов

Model&Method	# Trainable Parameters	WikiSQL	MNLI-m	SAMSum
		Acc. (%)	Acc. (%)	R1/R2/RL
GPT-3 (FT)	175,255.8M	73.8	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 (Adapter ^H)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 (Adapter ^H)	40.1M	73.2	91.5	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	91.7	53.8/29.8/45.9
GPT-3 (LoRA)	37.7M	74.0	91.6	53.4/29.2/45.1

QLoRA

Предназначена для дообучения очень больших моделей



$$\mathbf{Y}^{\text{BF16}} = \mathbf{X}^{\text{BF16}} \text{doubleDequant}(c_1^{\text{FP32}}, c_2^{\text{k-bit}}, \mathbf{W}^{\text{NF4}}) + \mathbf{X}^{\text{BF16}} \mathbf{L}_1^{\text{BF16}} \mathbf{L}_2^{\text{BF16}}$$