LLM scaling laws

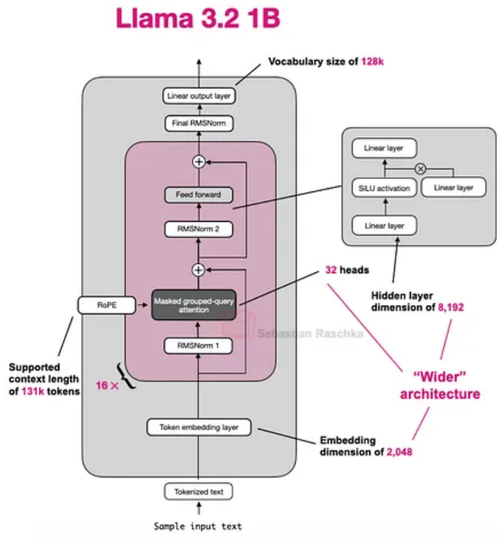
Как скейлить модель?

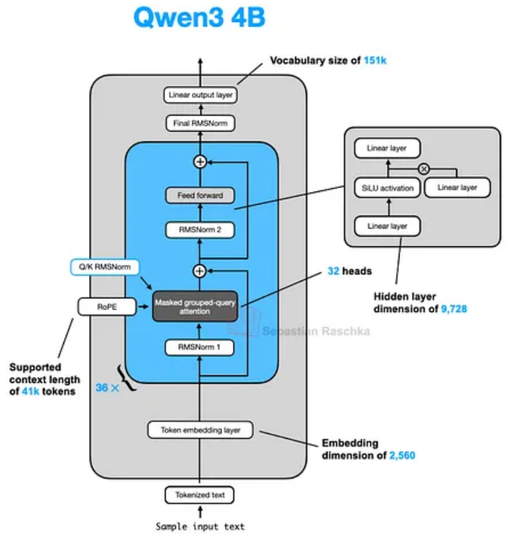
Задача:

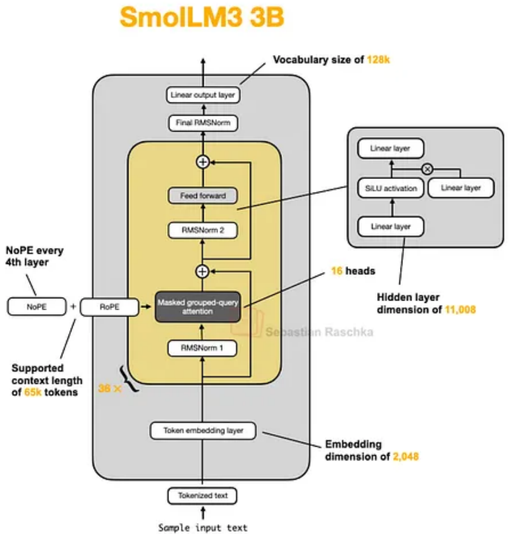
- У вас есть много ресурсов и вы хотите обучить большую модель (100B)
- Обучать большую модель дорого и вы можете сделать это только один раз
- Как понять, какую модель учить?

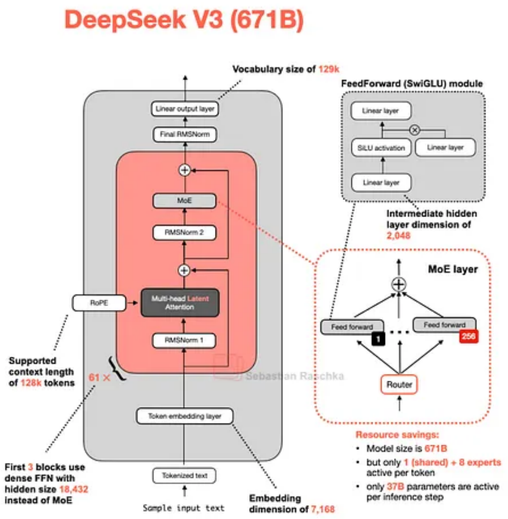
Как скейлить модель?

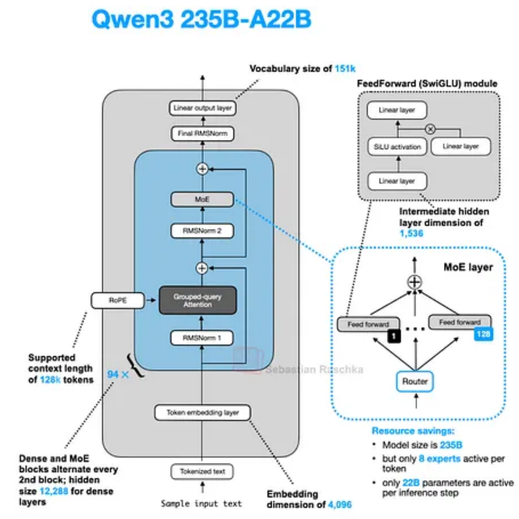
- Можно использовать чужую архитектуру
- Но тогда ваша модель не будет лучше

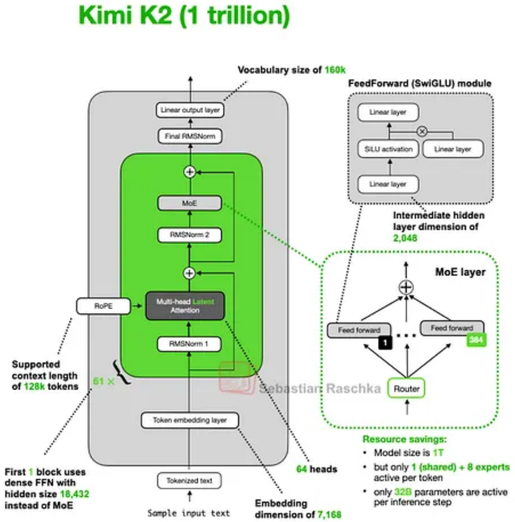






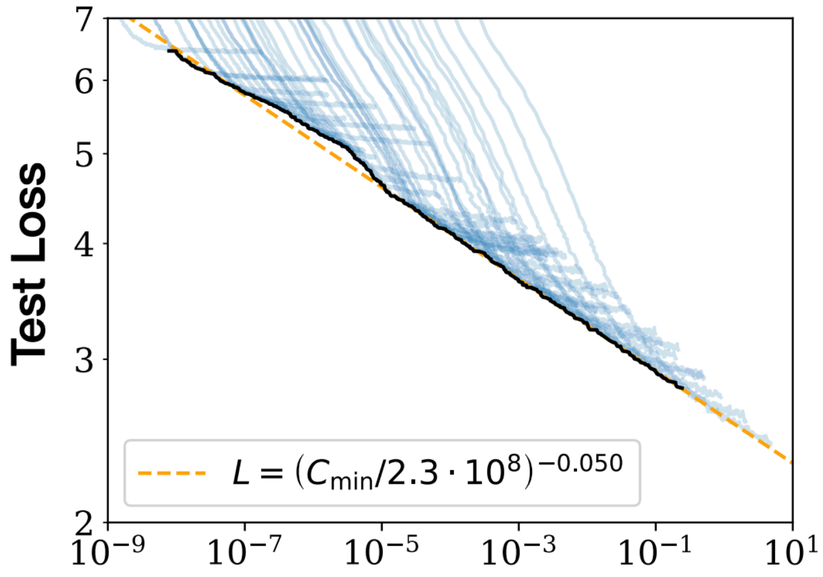






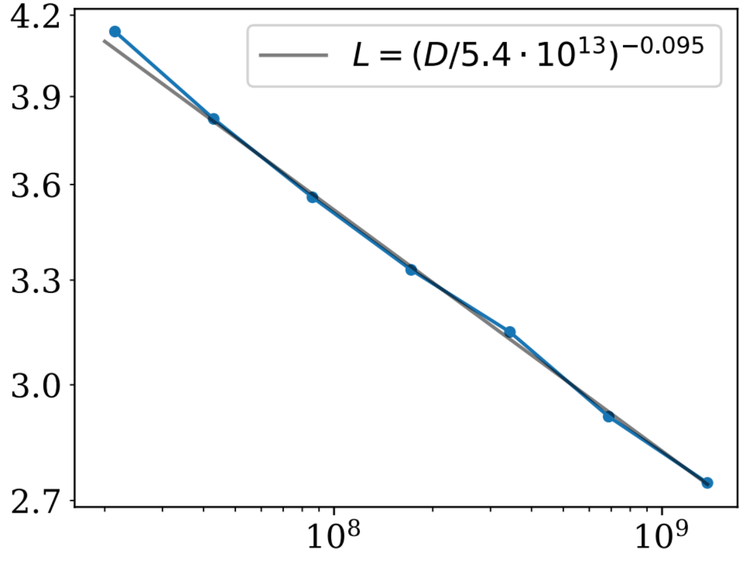
Scaling laws

Идея: обучить много моделей меньшего размера и найти простую зависимость между размером и качеством.



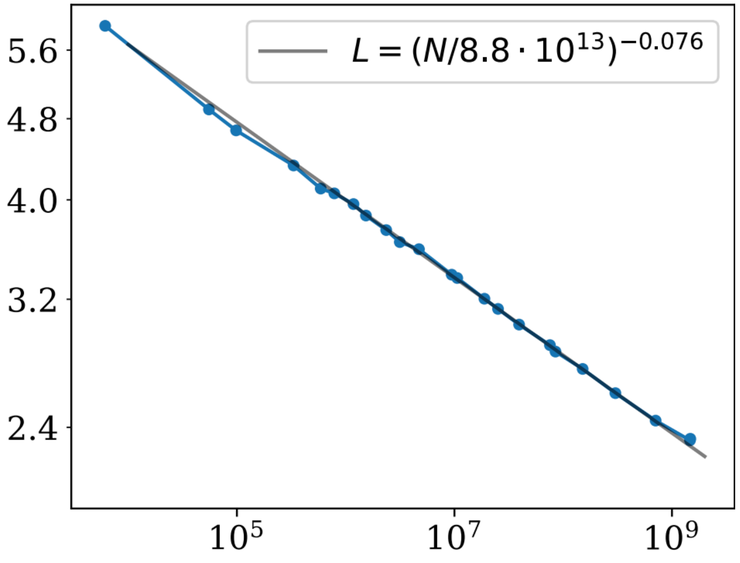
Compute

PF-days, non-embedding



Dataset Size

tokens

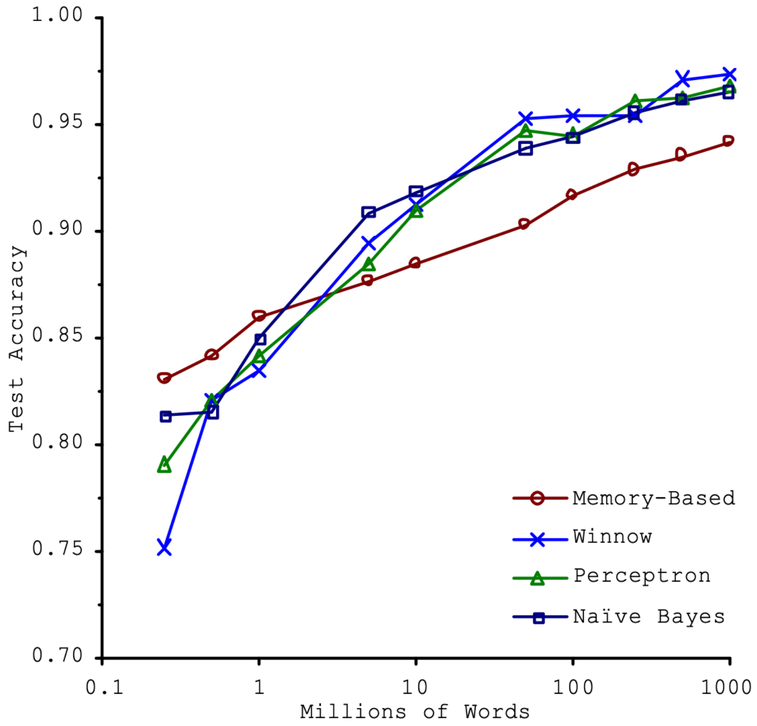


Parameters

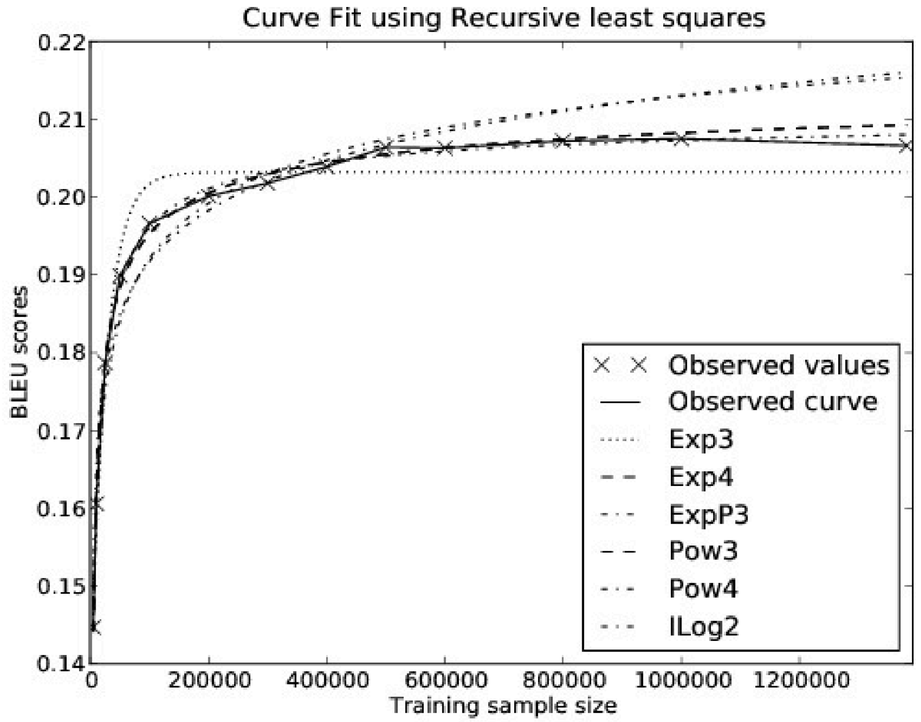
non-embedding

Data scaling

Очень естественно скейлить данные.
Законы для скейлинга исследуют уже давно.
Чаще всего скейлинг подчиняется степенному закону.



[Banko and Brill, 2001]

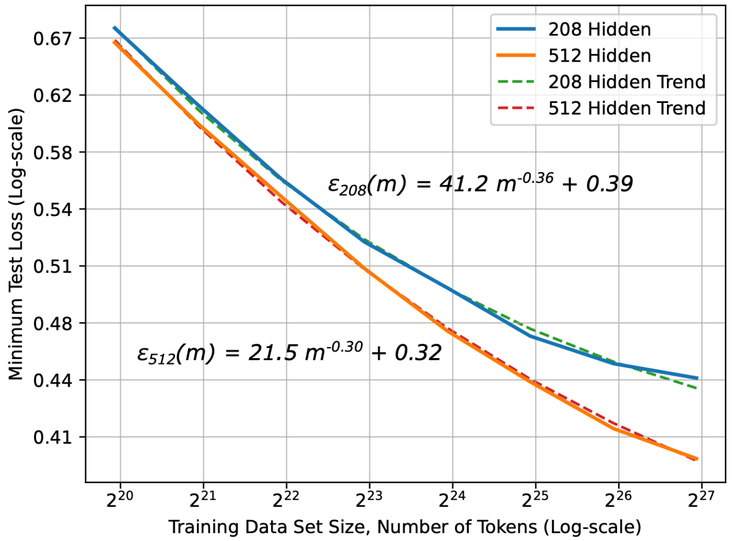


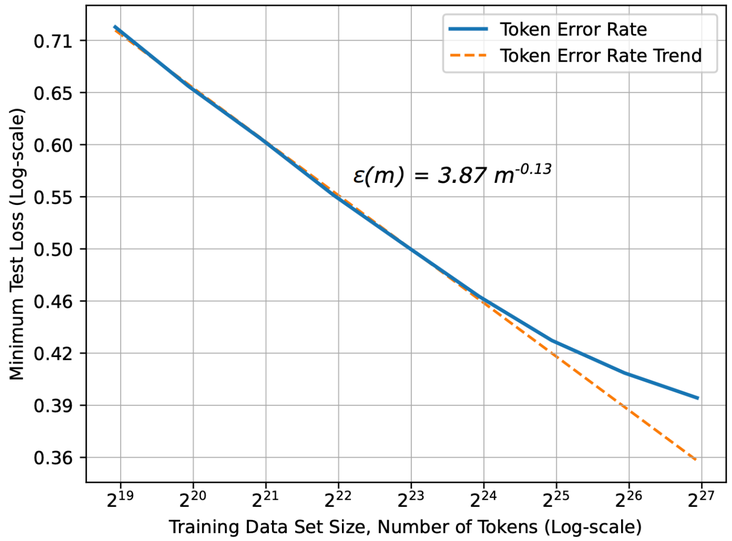
[Kolachina et al, 2012]

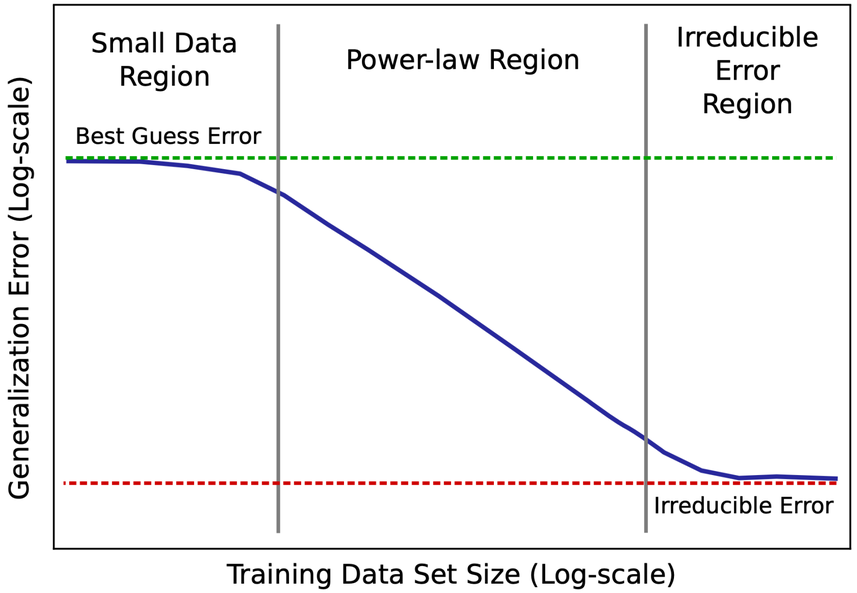
Скейлинг данных для нейронных сетей

Скейлинг данных имеет сигмоидальный вид:

- С одной стороны мы ограничены качеством случайного угадывания
- С другой – минимальной возможной ошибкой







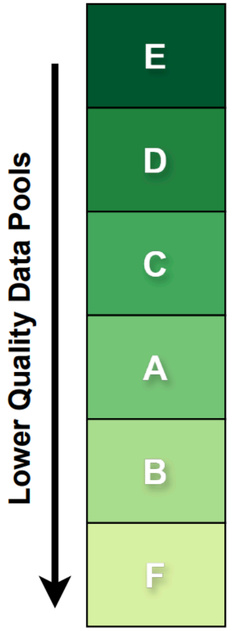
[Hestness et al, 2017]

На какие вопросы можно отвечать?

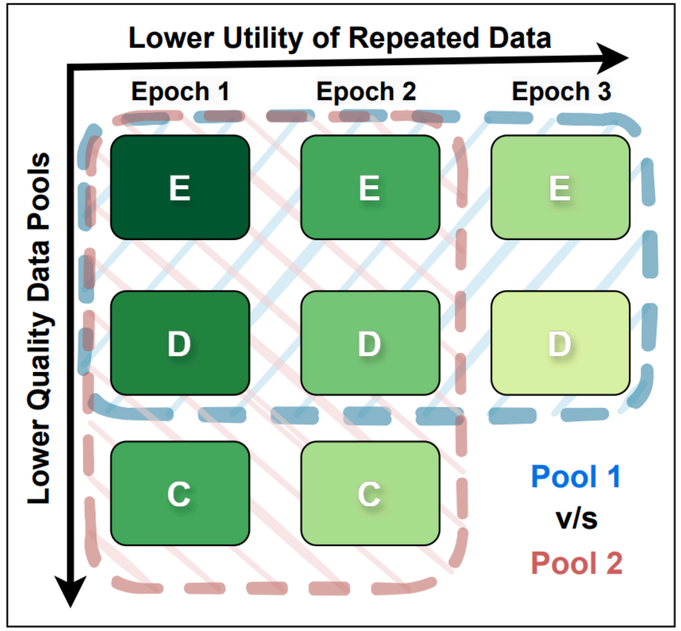
- В каких пропорциях смешивать данные из разных источников?
- Сколько раз можно повторять данные?

Выбор данных в ограниченных условиях

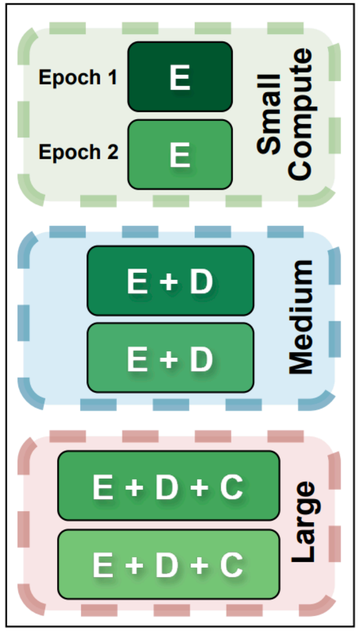
Качество данных надо выбирать в зависимости от компьюта



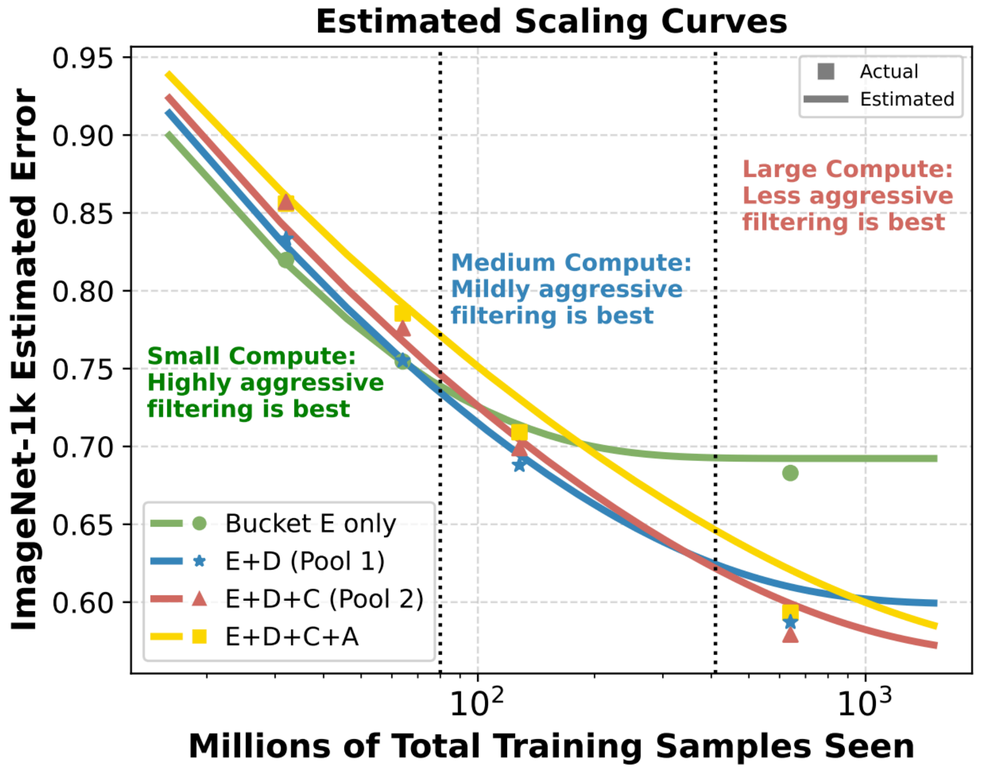
Web Data is Non-Homogenous



Quality-Quantity Tradeoff (QQT) for Data Filtering



Best Data Pool Changes with Total Compute



[Goyal et al, 2024]

Scaling laws для моделей

Как выбирать дизайн моделей?

- LSTM vs Трансформер vs Линейный Трансформер
- Feed forward MLP vs Mixture of Experts
- Adam vs SGD

На что лучше тратить ресурсы?

- Увеличить размер модели?
- Увеличить датасет?
- Учить дольше?

Выбор гиперпараметров

Обсудим:

- Архитектуру
- Оптимизаторы
- Ширина/глубина
- Размер батча

Scaling Laws for Neural Language Models

Jared Kaplan *
Johns Hopkins University, OpenAI
jaredk@jhu.edu

Sam McCandlish*
OpenAI
sam@openai.com

Tom Henighan
OpenAI
henighan@openai.com

Tom B. Brown
OpenAI
tom@openai.com

Benjamin Chess
OpenAI
bchess@openai.com

Rewon Child
OpenAI
rewon@openai.com

Scott Gray
OpenAI
scott@openai.com

Alec Radford
OpenAI
alec@openai.com

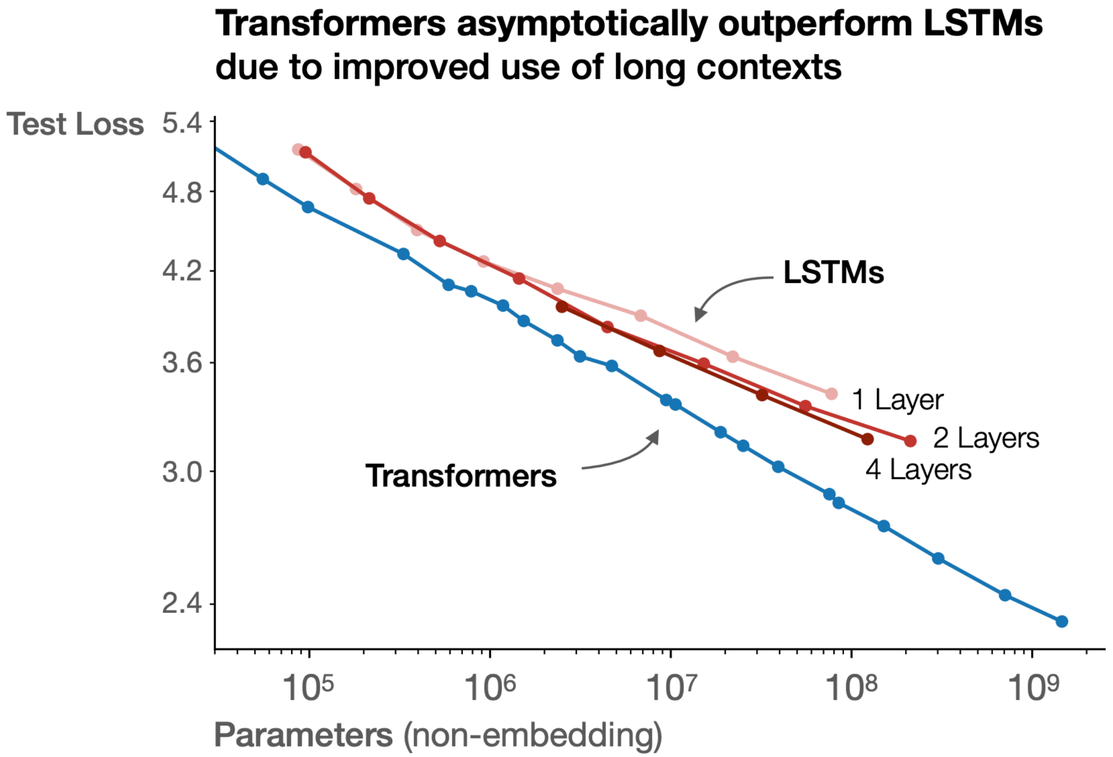
Jeffrey Wu
OpenAI
jeffwu@openai.com

Dario Amodei
OpenAI
damodei@openai.com

[Kaplan et al, 2020]

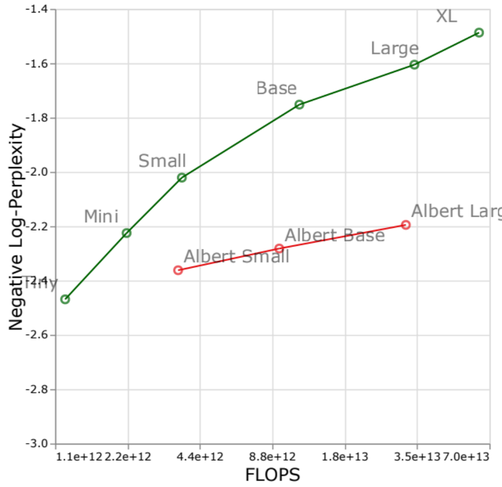
Выбор архитектуры

Лучше ли Трансформер, чем LSTM?
Scaling laws отвечают на этот вопрос

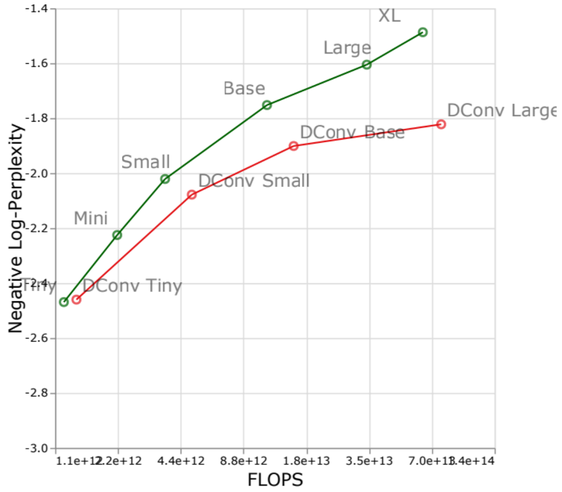


[Kaplan et al, 2020]

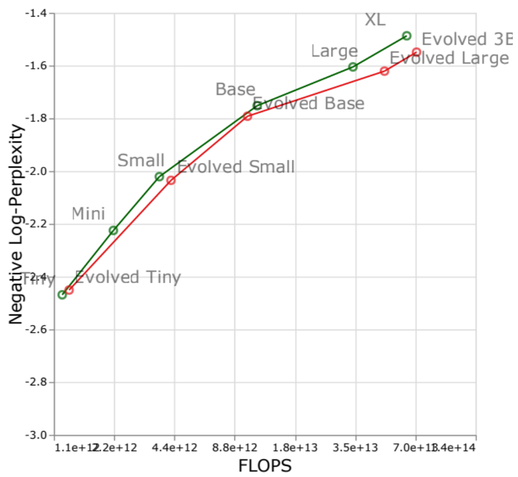
Выбор архитектуры



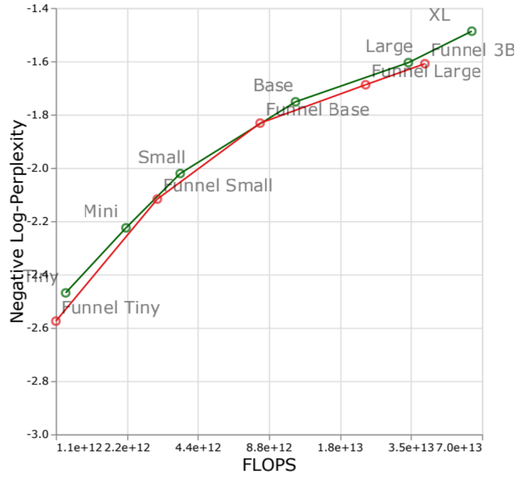
(a) ALBERT



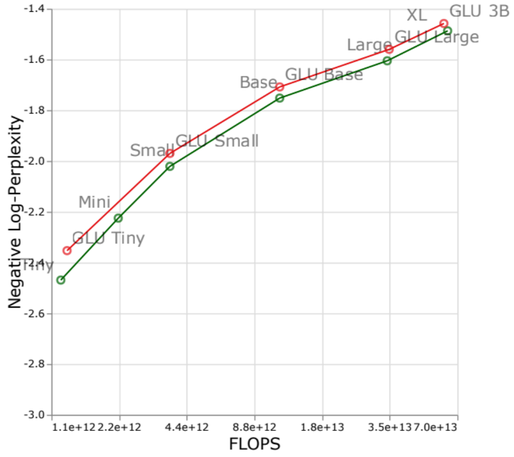
(b) DConv



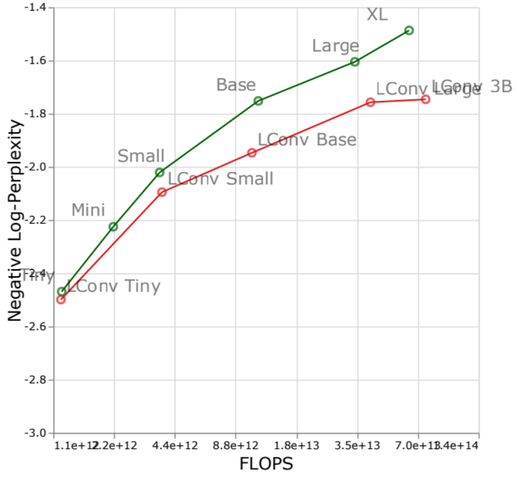
(c) Evolved



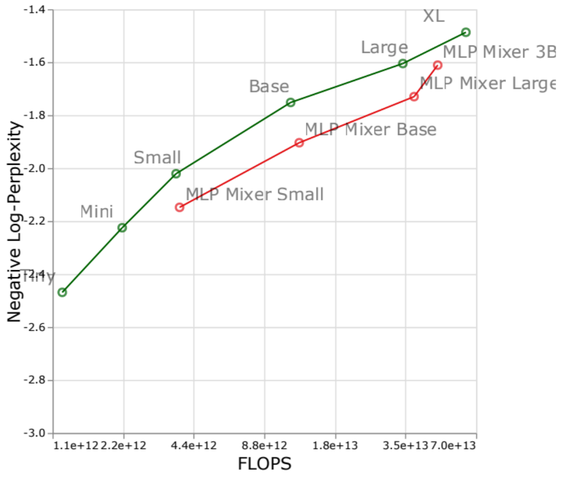
(d) Funnel



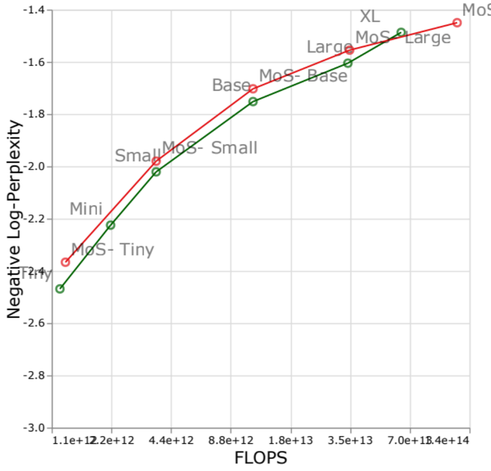
(e) Transformer-GLU



(f) LConv



(g) MLP Mixer

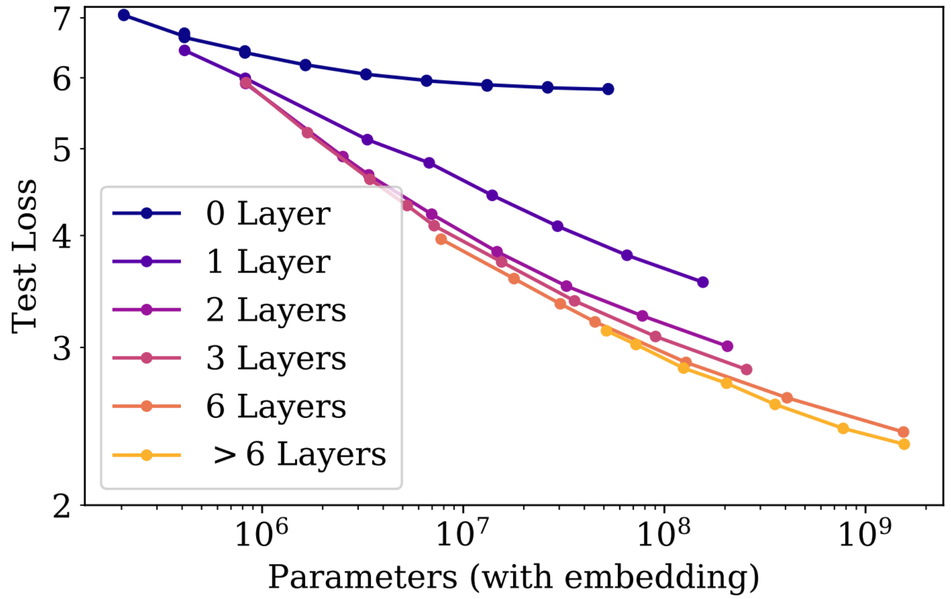


(h) MoS Transformer

[Tay et al, 2022]

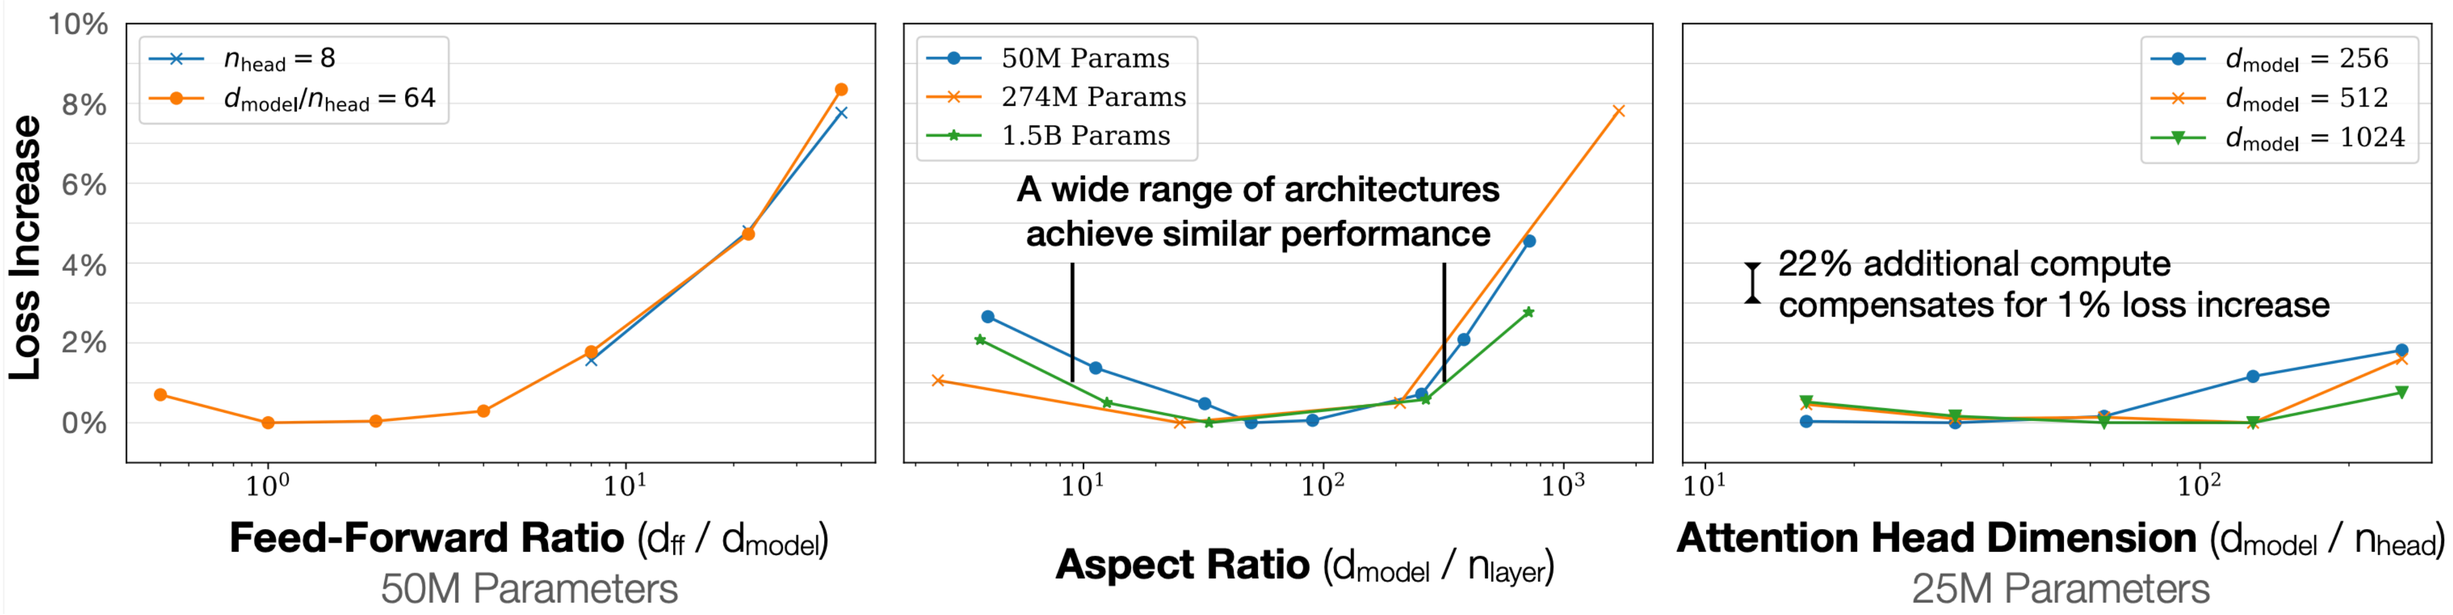
Ширина против глубины

- Колоссальная разница между 1 и 2 слоями
- При большом числе слоев становится не так важно



[Kaplan et al, 2020]

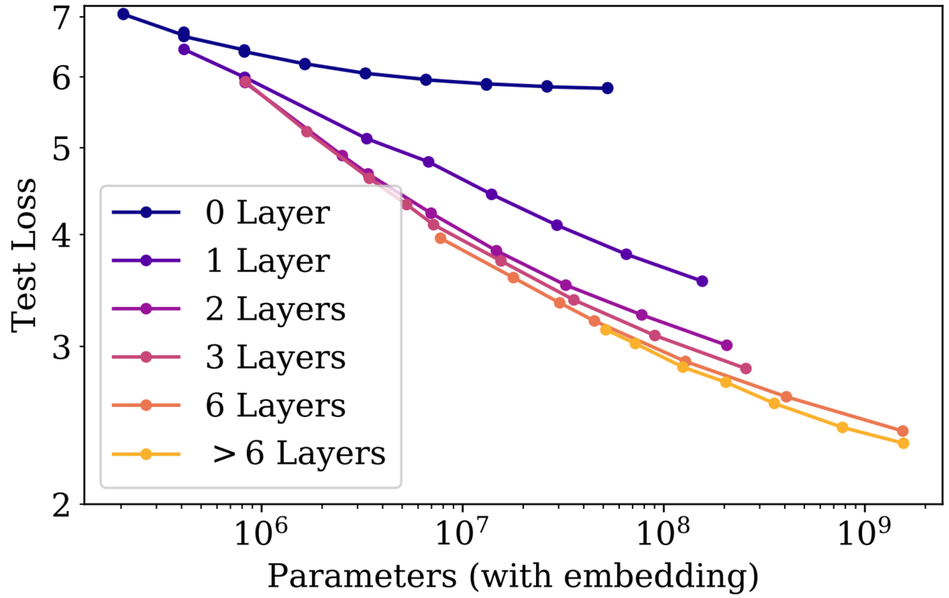
Ширина против глубины

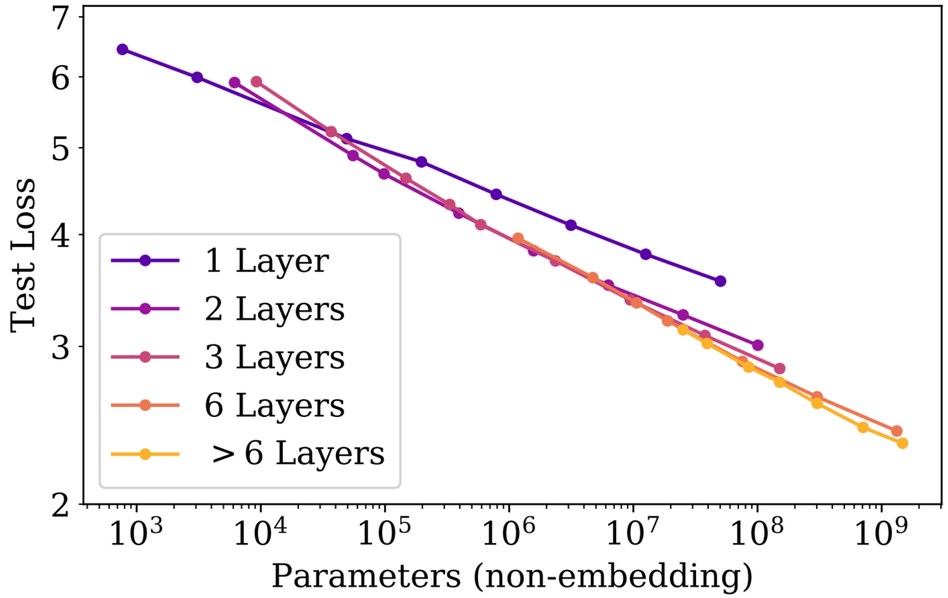


[Kaplan et al, 2020]

Ширина против глубины

- Не все параметры надо считать!
- Эмбеддинги не подчиняются тому же закону
- Очень важно правильно выбирать оси

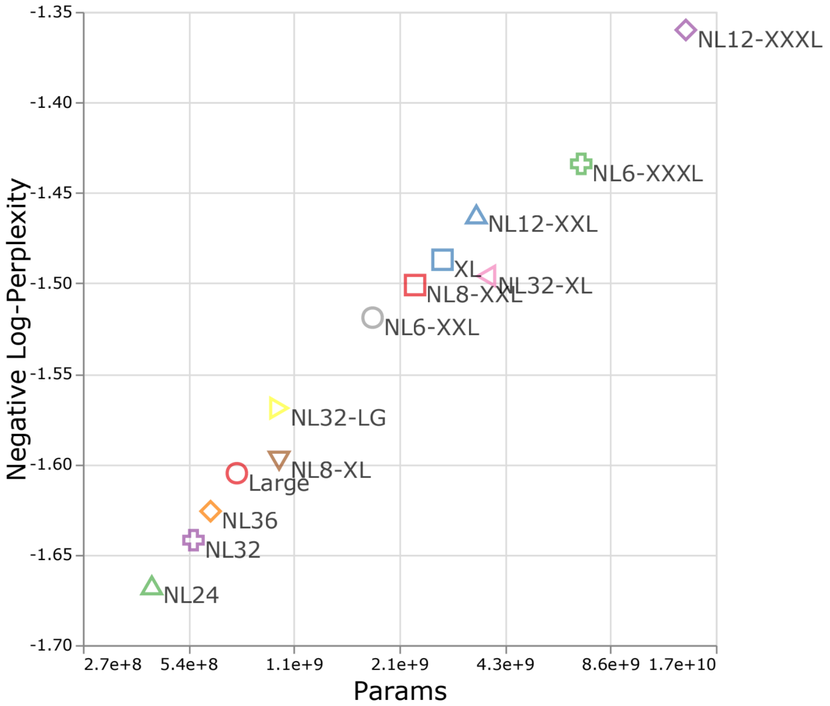




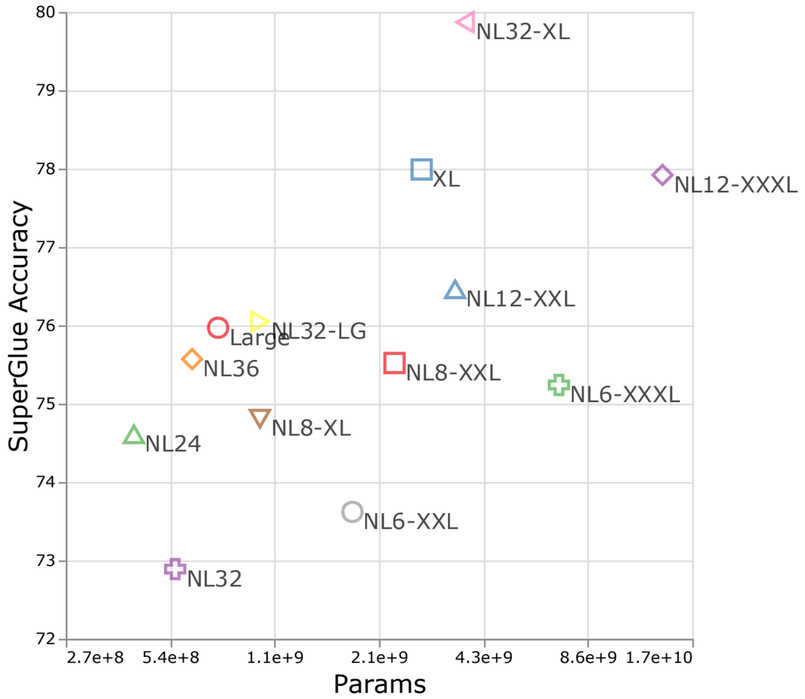
[Kaplan et al, 2020]

Pre-train vs Downstream

Качество во время обучения не всегда переносится на качество на бенчмарках



(a) Pre-training scaling

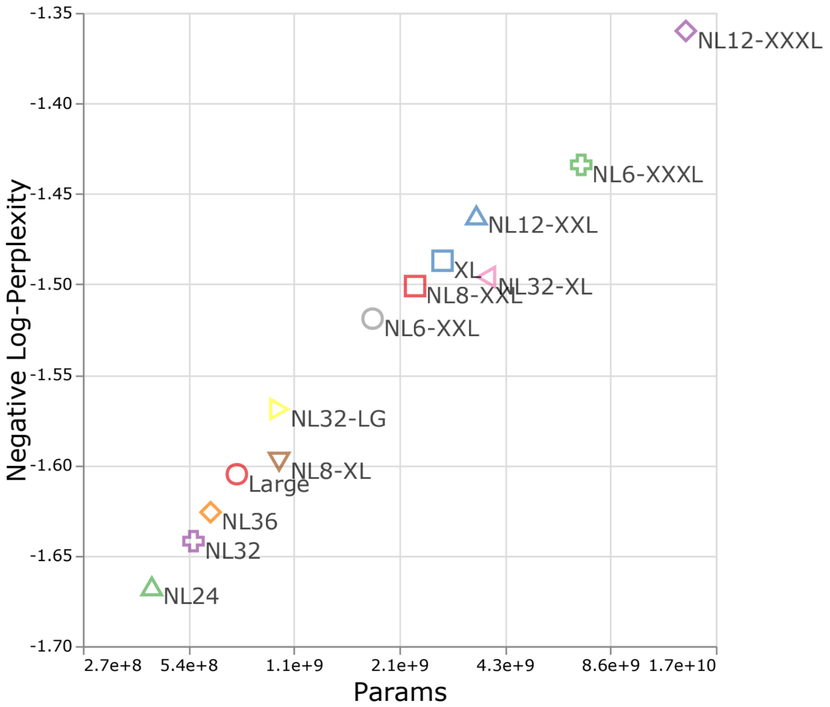


(b) Fine-tuning scaling

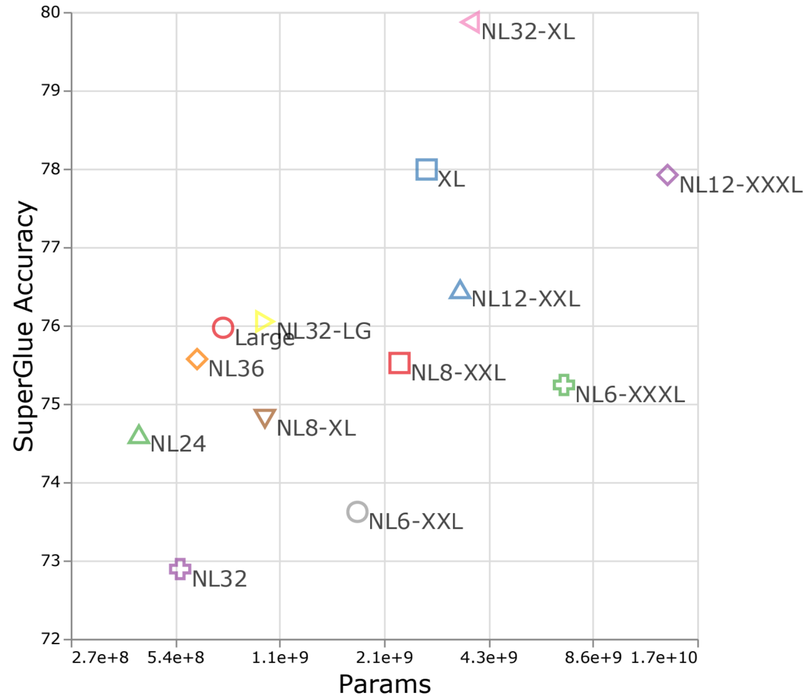
[Tay et al, 2023]

Pre-train vs Downstream

Качество во время обучения не всегда переносится на качество на бенчмарках



(a) Pre-training scaling



(b) Fine-tuning scaling

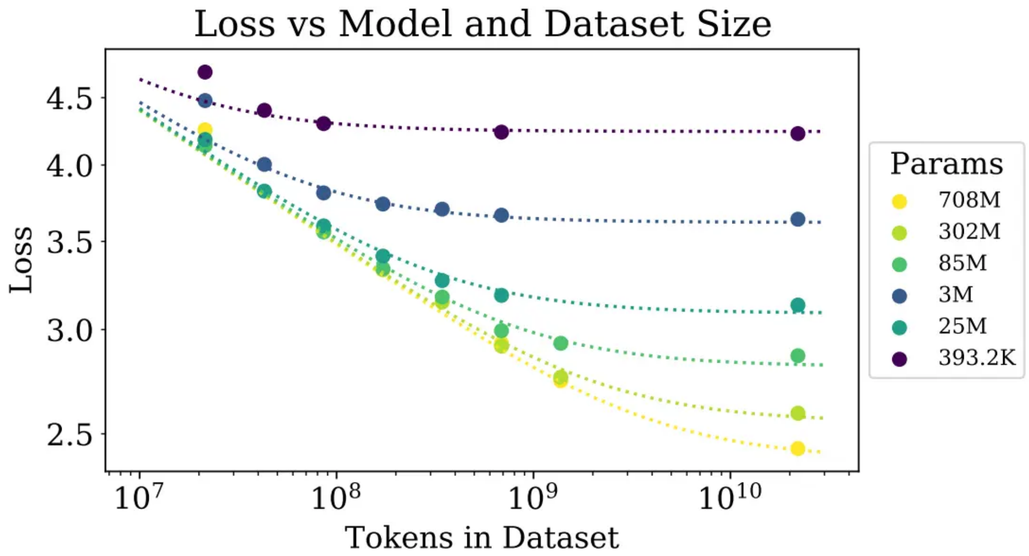
[Tay et al, 2023]

Evaluation. Loss and downstream accuracy do not always move together, and we observe disagreements in both directions. Enlarging the n-gram vocabulary lowers loss monotonically while downstream accuracy saturates, and under a fixed parameter budget the loss optimum diverges from the accuracy optimum

[Qwen3.8-Next, 2026]

Размер модели vs датасет

Увеличивать датасет без увеличения модели – деньги на ветер



Законы скейлинга говорят примерно одно и то же

m – модель

n – токены

Rosenfeld, 2021

$$Error = n^{-\alpha} + m^{-\beta} + C$$

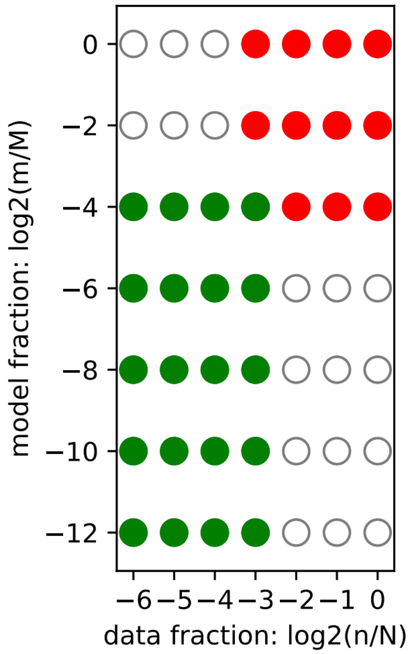
Kaplan et al, 2020

$$Error = [m^{-\alpha} + n^{-1}]^{\beta}$$

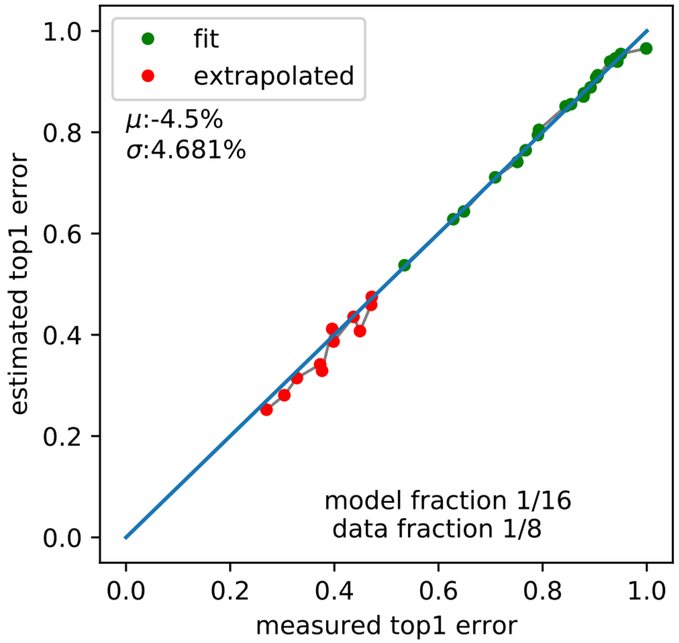
Размер модели vs датасет

Рецепт scaling laws

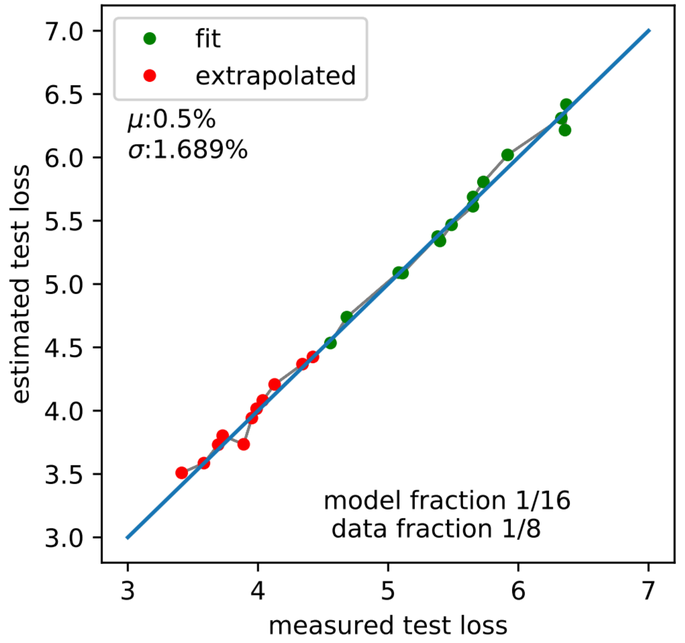
1. Обучаем много маленьких моделей
2. Получаем степенной закон
3. Выбираем параметры для больших моделей на основании закона



(a) Illustration.



(b) Extrapolation on ImageNet



(c) Extrapolation on WikiText-103.

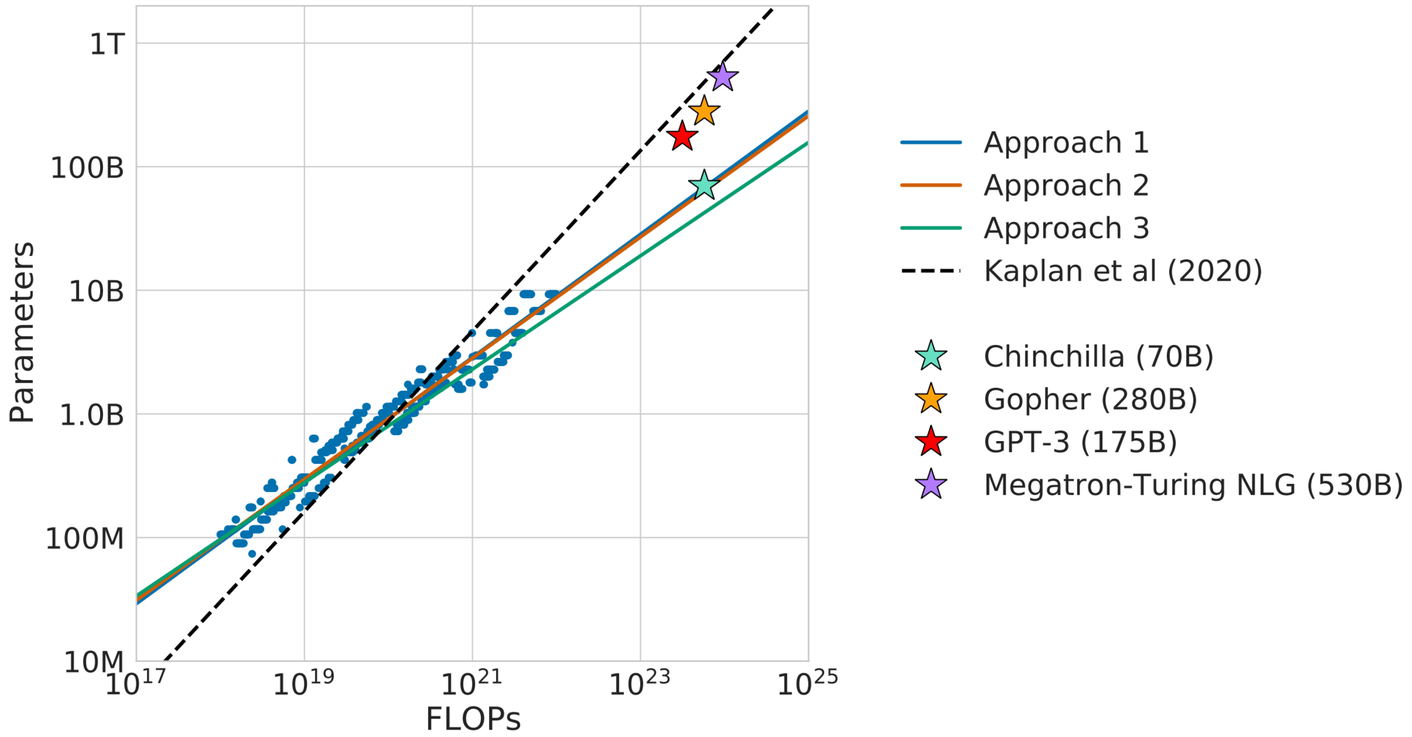
[Rosenfeld, 2021]

Chinchilla scaling laws

Kaplan et al утверждает, что $N_{opt} = C^{0.73}, D_{opt} = C^{0.27}$

То есть модель растет быстрее датасета

Chinchilla говорит, что это не так

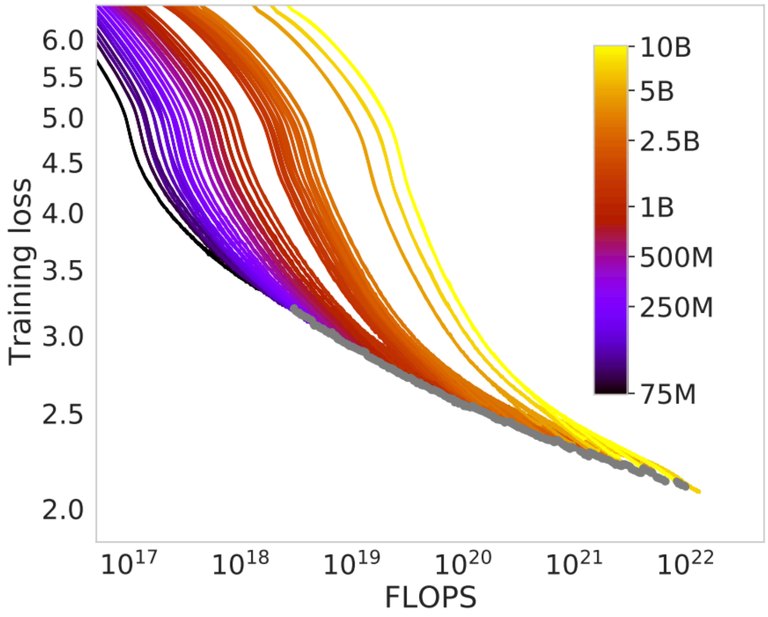


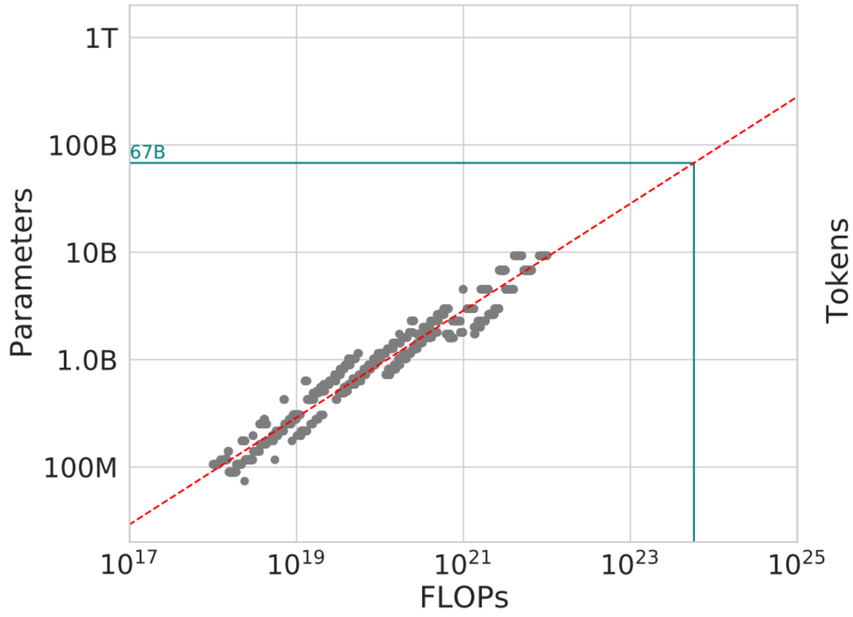
[Hoffman et al, 2022]

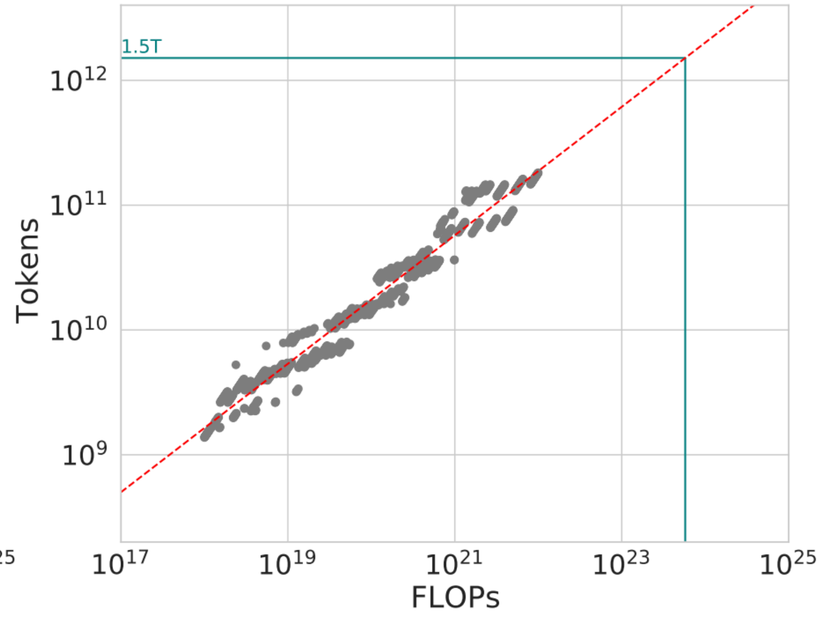
Как находить закон?

1. Training curve envelope

1. Обучаем много моделей
2. Для каждого значения FLOPS берем нижнюю точку
3. Рисуем зависимости





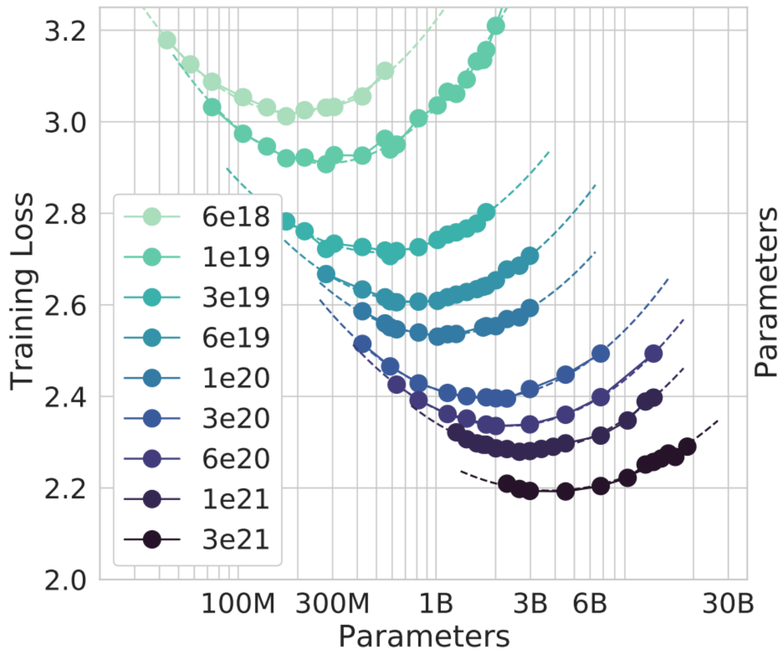


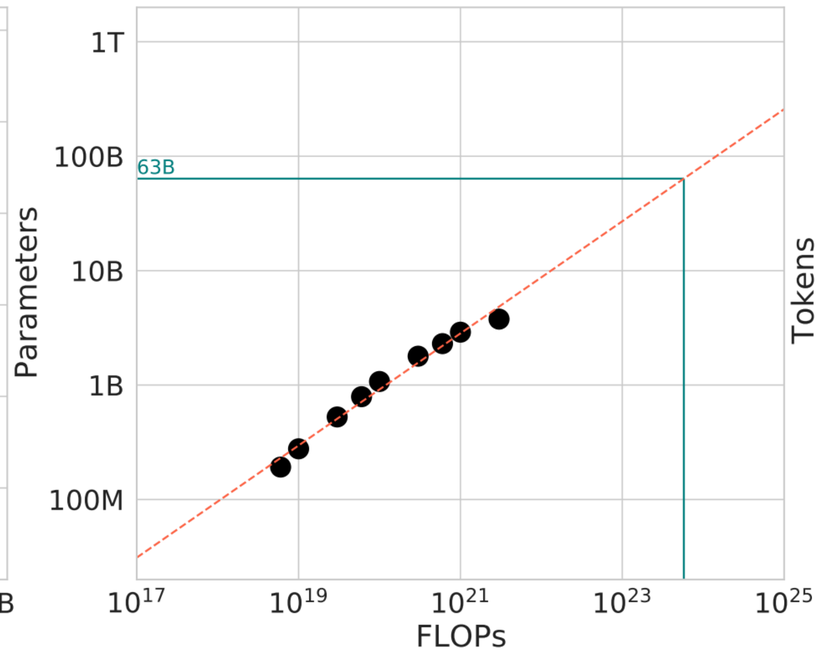
[Hoffman et al, 2022]

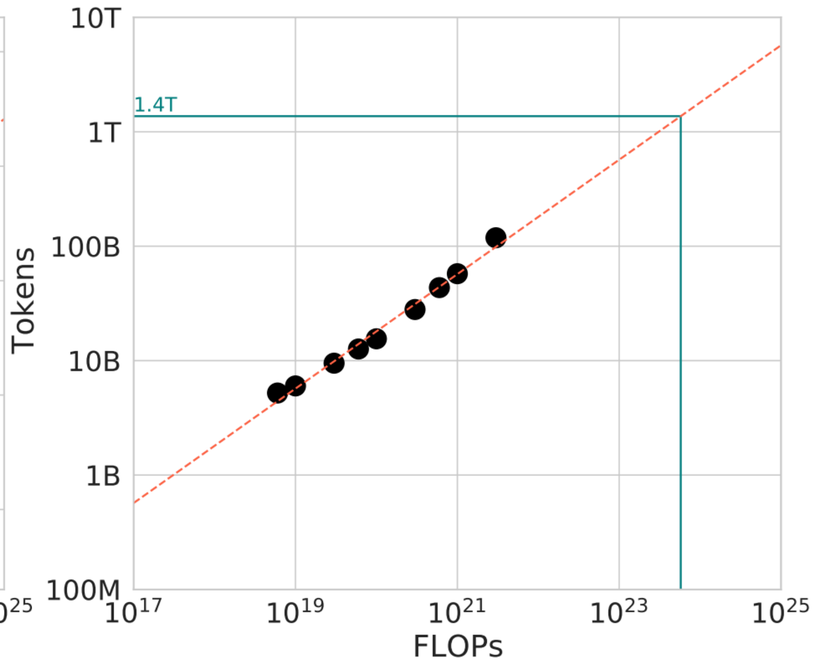
Как находить закон?

2. IsoFLOP curves

1. Обучаем много моделей фиксированное число FLOPS
2. По результатам подгоняем параболы
3. На графике откладываем минимальные точки против FLOPS





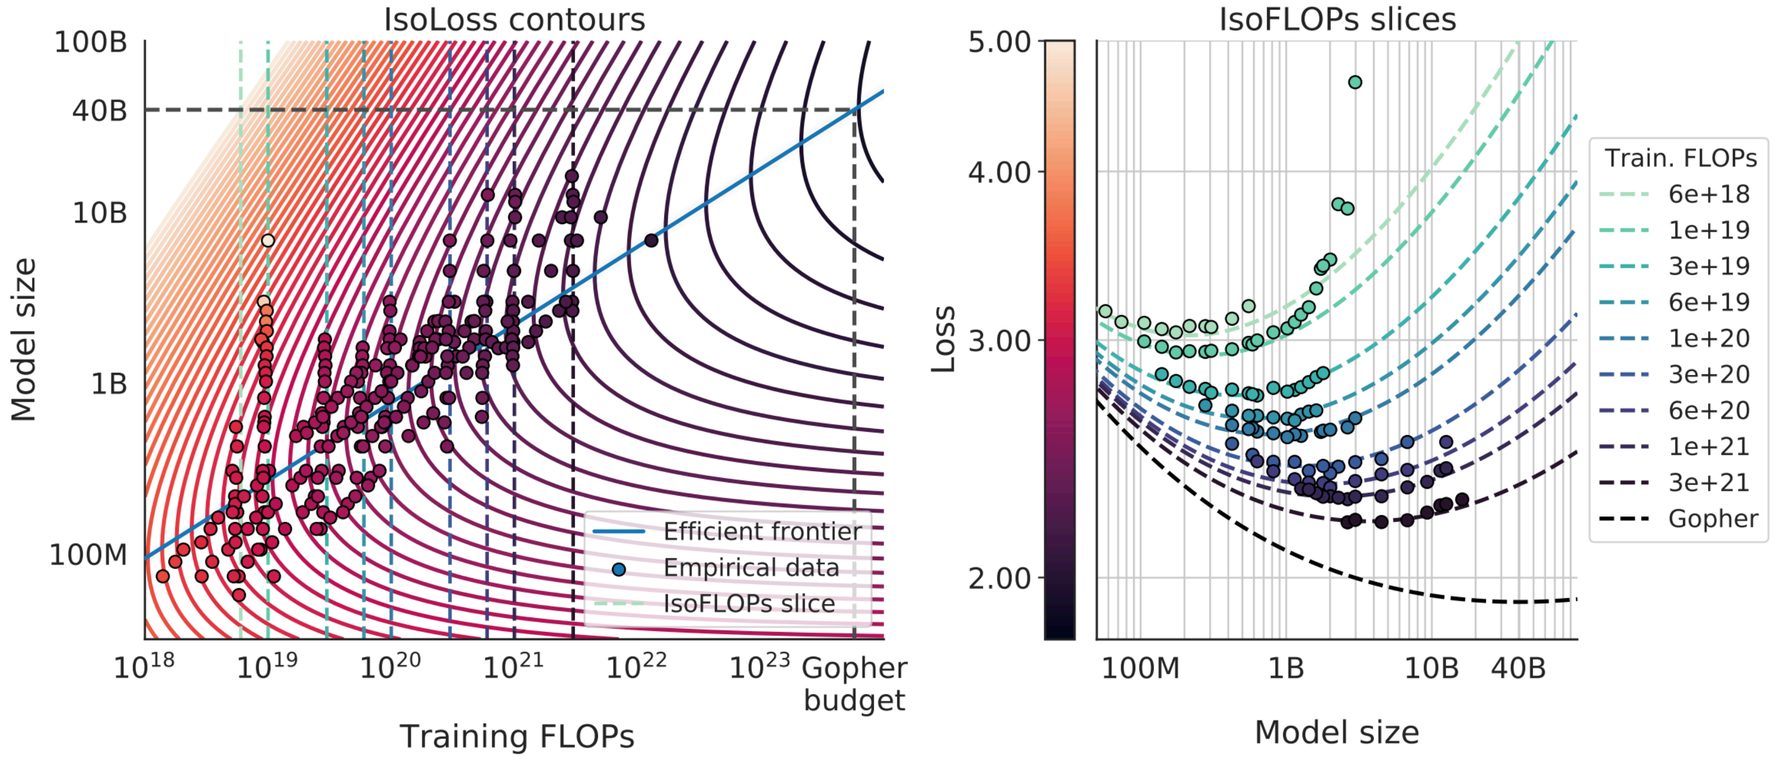


[Hoffman et al, 2022]

Как находить закон?

3. Parametric fit

1. Обучаем много моделей фиксированное число FLOPS
2. По результатам подгоняем параболы (справа)
3. Откладываем размер модели против FLOPS и IsoFLOPs срезами (слева)
4. Подгоняем закон под полученную зависимость (слева)



[Hoffman et al, 2022]

Сравнение трех подходов

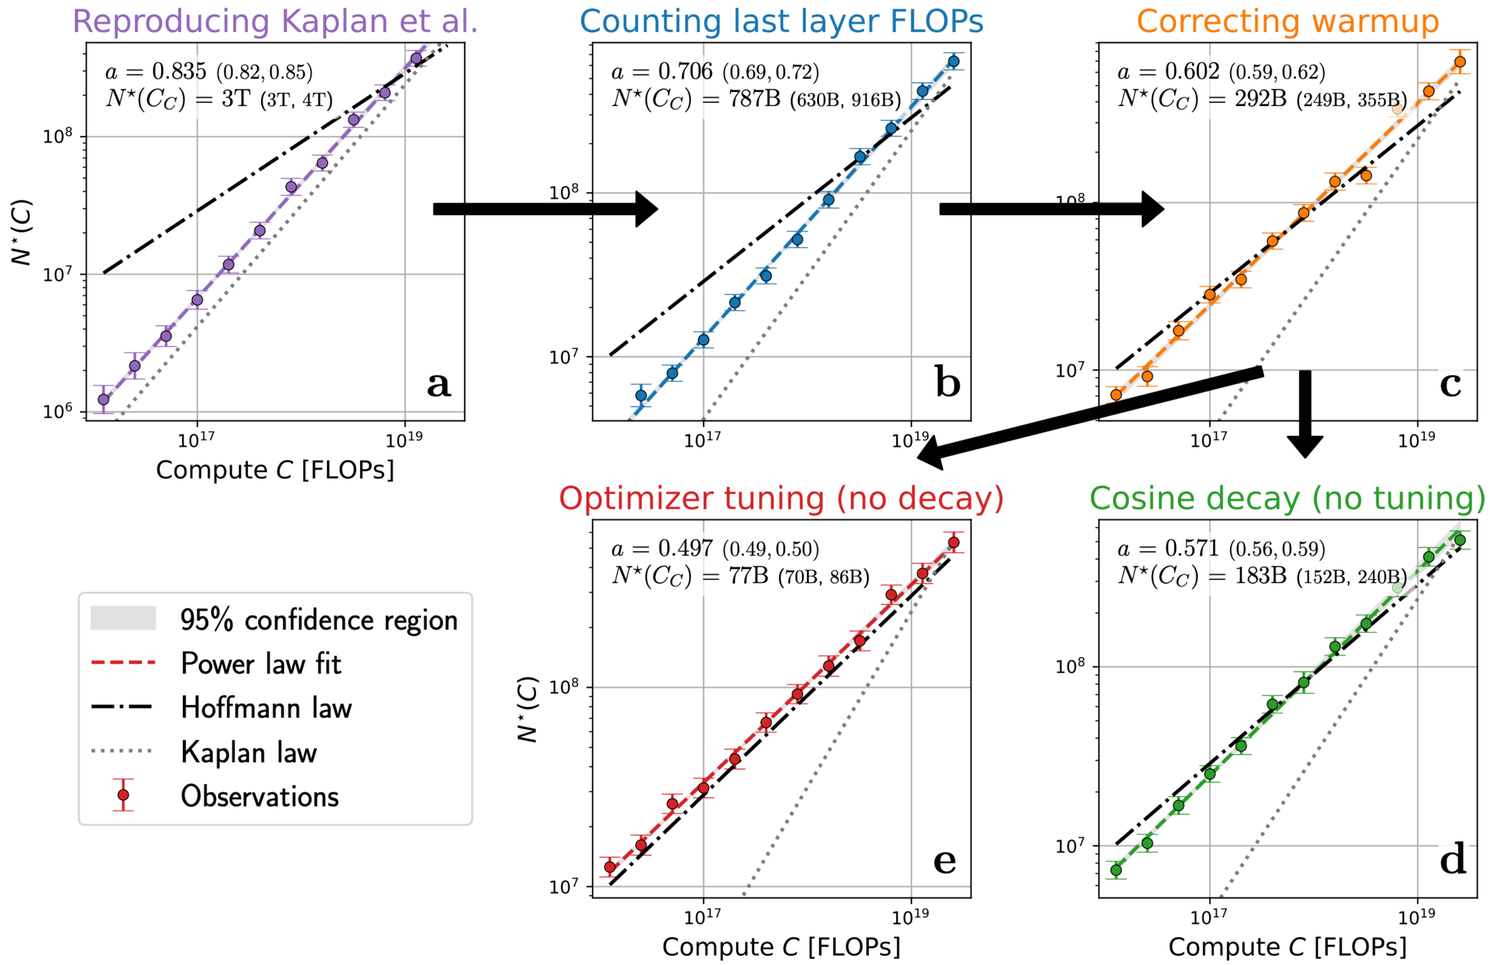
Все три подхода согласуются и говорят, что размер модели и объем данных должны расти с одной скоростью ($D = 20N$)

Approach	Coeff. a where $N_{opt} \propto C^a$	Coeff. b where $D_{opt} \propto C^b$
1. Minimum over training curves	0.50 (0.488, 0.502)	0.50 (0.501, 0.512)
2. IsoFLOP profiles	0.49 (0.462, 0.534)	0.51 (0.483, 0.529)
3. Parametric modelling of the loss	0.46 (0.454, 0.455)	0.54 (0.542, 0.543)
Kaplan et al. (2020)	0.73	0.27

[Hoffman et al, 2022]

Откуда такая разница с Kaplan?

1. Kaplan не считает **параметры последнего слоя**
2. Kaplan использует слишком большой **warmup** для маленьких моделей
3. **Learning rate** был неоптимально подобран



[Porian et al, 2025]

Как на самом деле?

В жизни мы хотим иметь модели поменьше, чтобы дешевле инференсить
Поэтому лучше тратить компьют на более долгое обучение

Модель	Токены/параметры
GPT3	2
Chinchilla	20
LLaMA65B	22
Llama 2 70B	29
Mistral 7B	110
Llama 3 70B	215

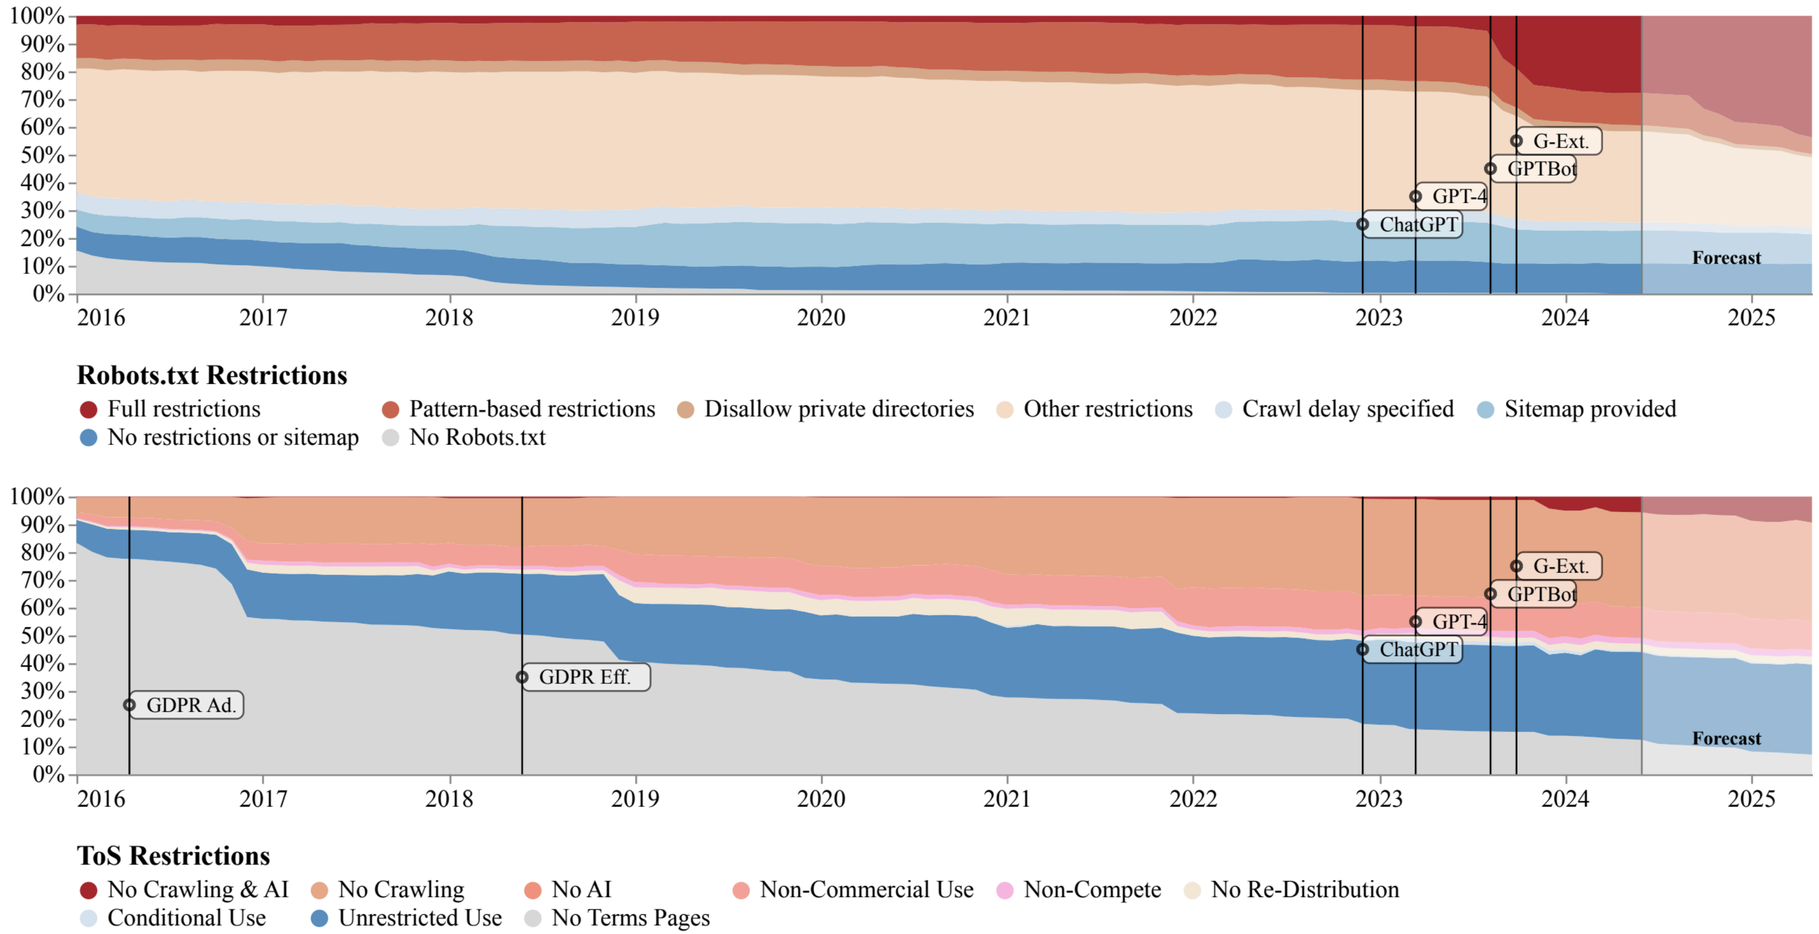
Датасеты

Данные – сложно

- LLM не тренируются *на всем интернете*
- Не до всех данных можно добраться автоматизацией

Данные – сложно

- LLM не тренируются *на всем интернете*
- Не до всех данных можно добраться автоматизацией
- Надо учитывать легальность использования данных



Данные – сложно

- **Common Crawl** – проект по сбору всех доступных данных из интернета. Содержит 300В скаченных страниц.
- Сложности обработки:
  - Парсинг html, LaTeX и pdf
  - Фильтрация по качеству (статистики, модели)
  - Фильтрация по языку
  - Дедупликация

Дедупликация

- Что считать объектом для дедупликации?
  (Документ? Абзац? Предложение?)

- Как изменять совпадение?
  (Полное совпадение? Частичное?)

Дедупликация

- Что считать объектом для дедупликации?
  (Документ? Абзац? Предложение?)

- Как изменять совпадение?
  (Полное совпадение? Частичное?)

Colossal Cleaned Crawled Corpus (C4)

- **Объекты:** последовательность из 3 предложений
- **Критерий удаления:** полное совпадение

Дедупликация

Частичное совпадение

Мера Жаккара: $J(A,B) = \frac{|A \cap B|}{|A \cup B|} > p$

Проблема: долго считать

Дедупликация

Частичное совпадение

Мера Жаккара: $J(A, B) = \frac{|A \cap B|}{|A \cup B|} > p$

Проблема: долго считать

MinHash

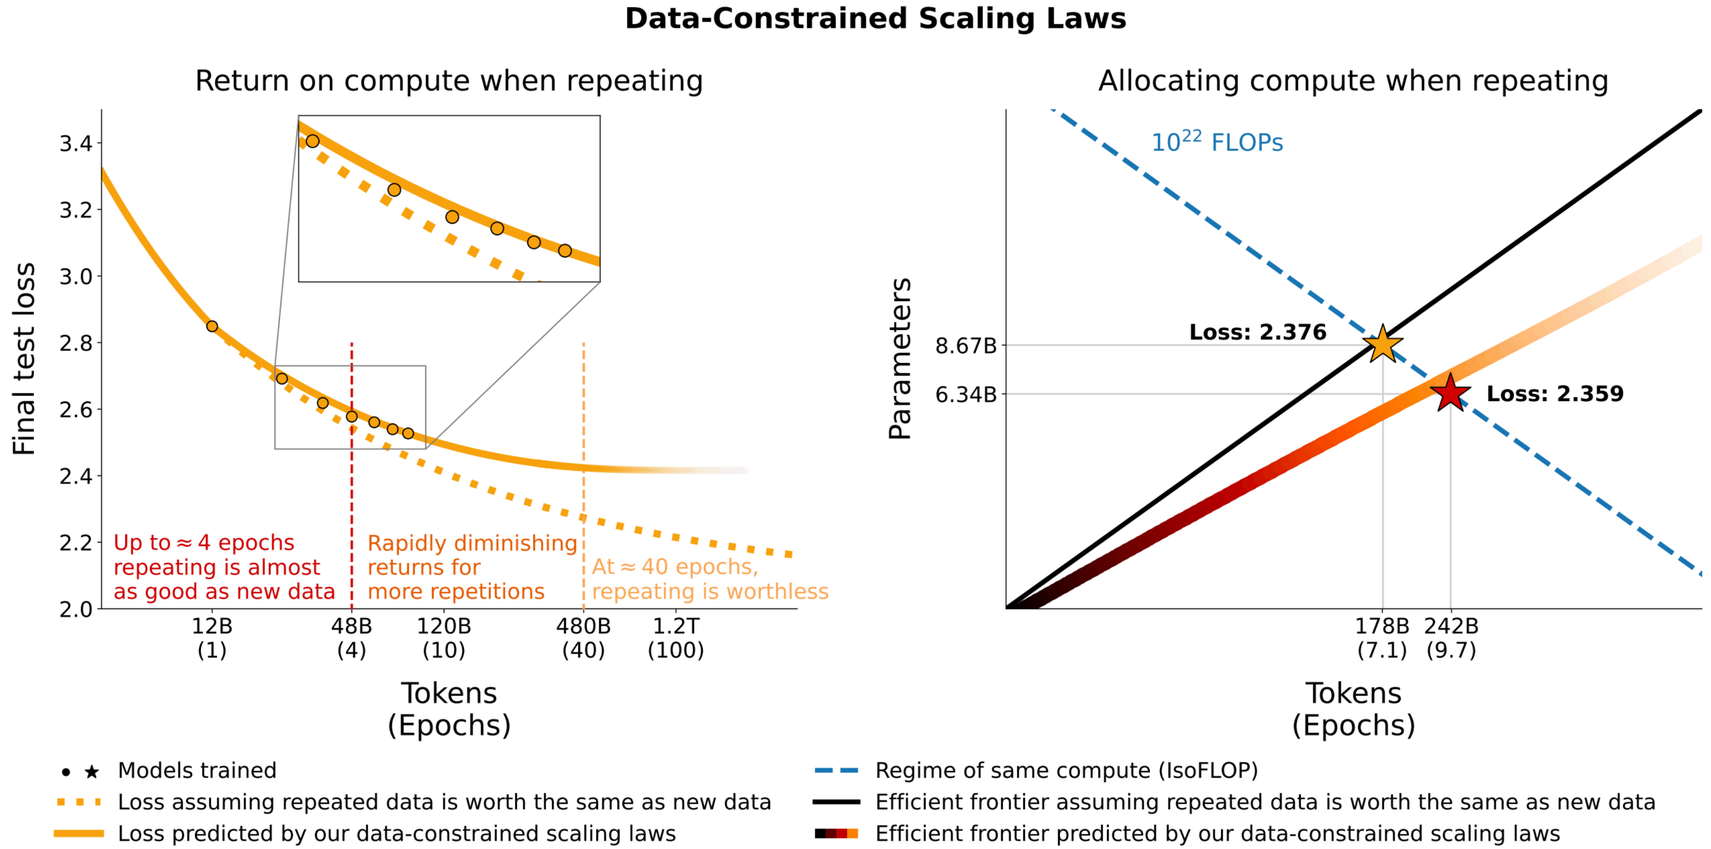
Совпадение минимальных хэшей элементов последовательностей

```
def minhash(S: set[str], seed: int):
        return min(mmh3.hash(x, seed) for x in S)
```

P[minhash(A) = minhash(B)] = J(A, B)

Повторение данных

Больше 4 эпох по одним данным лучше не делать



[Muennighoff et al, 2025]

Как смешивать данные?

Component	Raw Size	Weight	Epochs	Effective Size	Mean Document Size
Pile-CC	227.12 GiB	18.11%	1.0	227.12 GiB	4.33 KiB
PubMed Central	90.27 GiB	14.40%	2.0	180.55 GiB	30.55 KiB
Books3†	100.96 GiB	12.07%	1.5	151.44 GiB	538.36 KiB
OpenWebText2	62.77 GiB	10.01%	2.0	125.54 GiB	3.85 KiB
ArXiv	56.21 GiB	8.96%	2.0	112.42 GiB	46.61 KiB
Github	95.16 GiB	7.59%	1.0	95.16 GiB	5.25 KiB
FreeLaw	51.15 GiB	6.12%	1.5	76.73 GiB	15.06 KiB
Stack Exchange	32.20 GiB	5.13%	2.0	64.39 GiB	2.16 KiB
USPTO Backgrounds	22.90 GiB	3.65%	2.0	45.81 GiB	4.08 KiB
PubMed Abstracts	19.26 GiB	3.07%	2.0	38.53 GiB	1.30 KiB
Gutenberg (PG-19)†	10.88 GiB	2.17%	2.5	27.19 GiB	398.73 KiB
OpenSubtitles†	12.98 GiB	1.55%	1.5	19.47 GiB	30.48 KiB
Wikipedia (en)†	6.38 GiB	1.53%	3.0	19.13 GiB	1.11 KiB
DM Mathematics†	7.75 GiB	1.24%	2.0	15.49 GiB	8.00 KiB
Ubuntu IRC	5.52 GiB	0.88%	2.0	11.03 GiB	545.48 KiB
BookCorpus2	6.30 GiB	0.75%	1.5	9.45 GiB	369.87 KiB
EuroParl†	4.59 GiB	0.73%	2.0	9.17 GiB	68.87 KiB
HackerNews	3.90 GiB	0.62%	2.0	7.80 GiB	4.92 KiB
YoutubeSubtitles	3.73 GiB	0.60%	2.0	7.47 GiB	22.55 KiB
PhilPapers	2.38 GiB	0.38%	2.0	4.76 GiB	73.37 KiB
NIH ExPorter	1.89 GiB	0.30%	2.0	3.79 GiB	2.11 KiB
Enron Emails†	0.88 GiB	0.14%	2.0	1.76 GiB	1.78 KiB
The Pile	**825.18 GiB**			**1254.20 GiB**	**5.91 KiB**

[The Pile, 2020]

Как смешивать данные?

Wikipedia: 0.4
Books3: 0.25
HackerNews: 0.05
GitHub: 0.2
ArXiv: 0.1

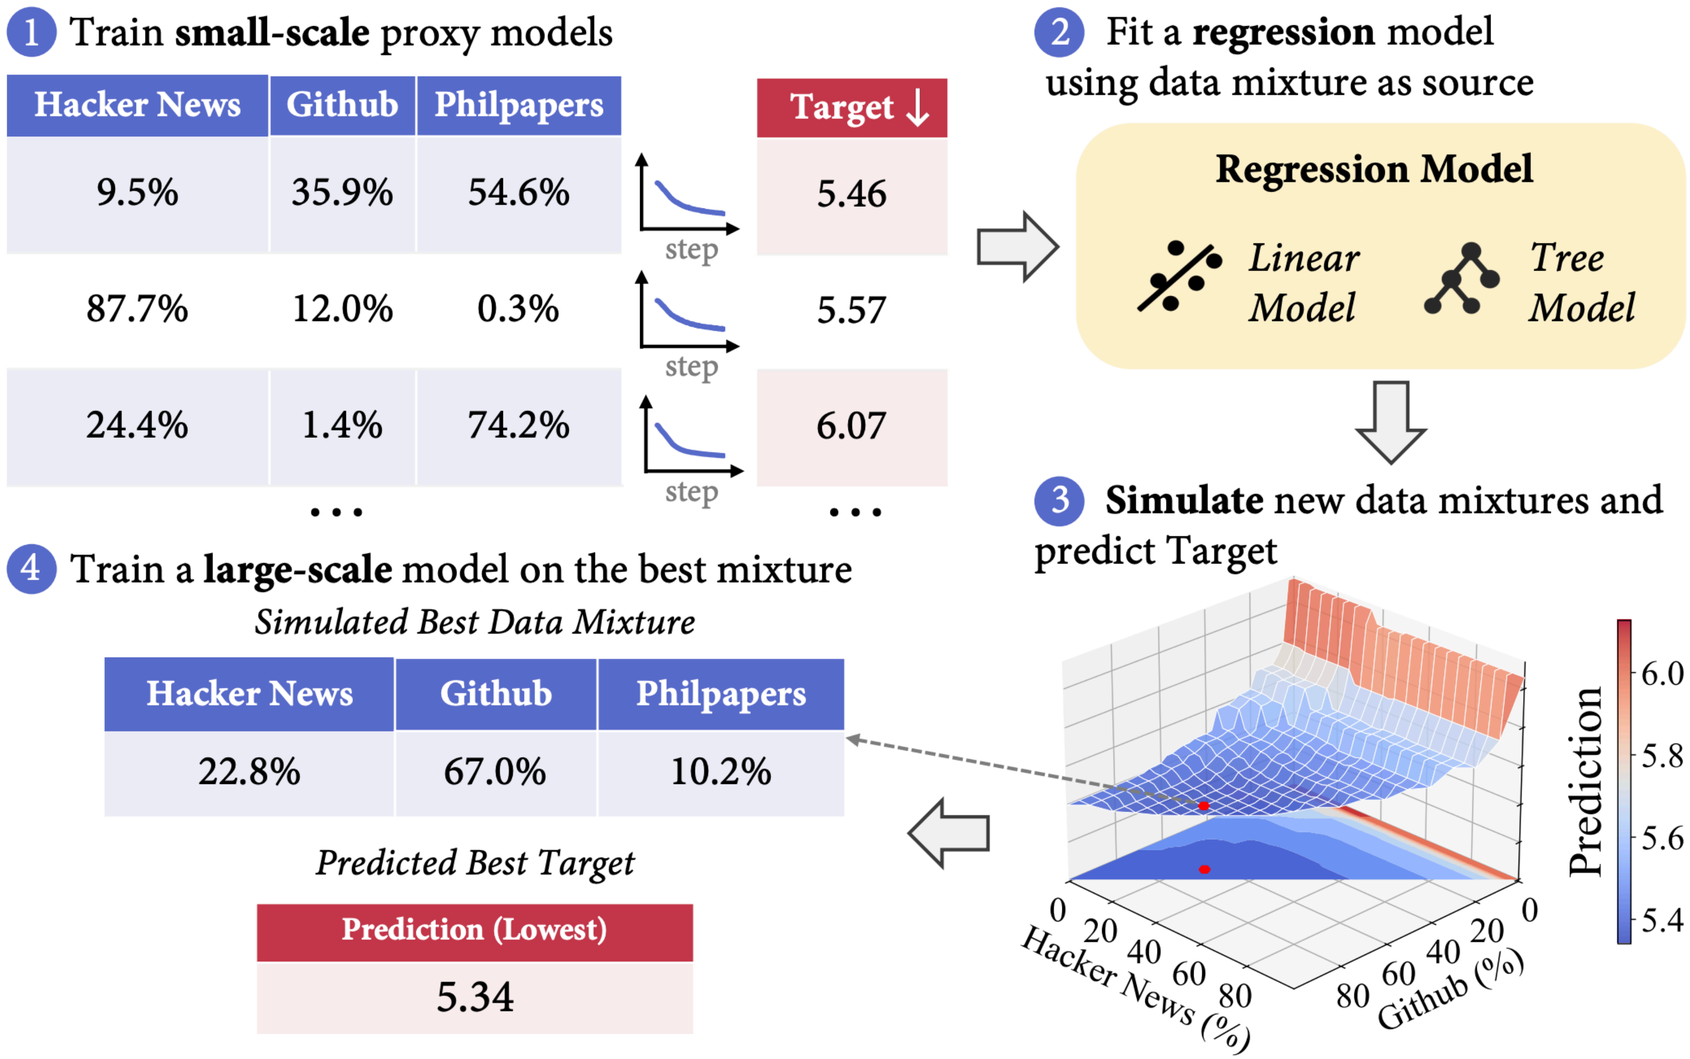
Как смешивать данные?

Wikipedia: 0.4
Books3: 0.25
HackerNews: 0.05
GitHub: 0.2
ArXiv: 0.1

Бейзлайны:

- Интуитивно
- Равномерно: $p(s) \propto 1$
- По размеру датасета: $p(s) \propto \text{tokens}(s)$

Поиск оптимальной смеси: RegMix



Важна аккуратность в выборе параметров, моделей и таргета.

[Liu et al, 2024]

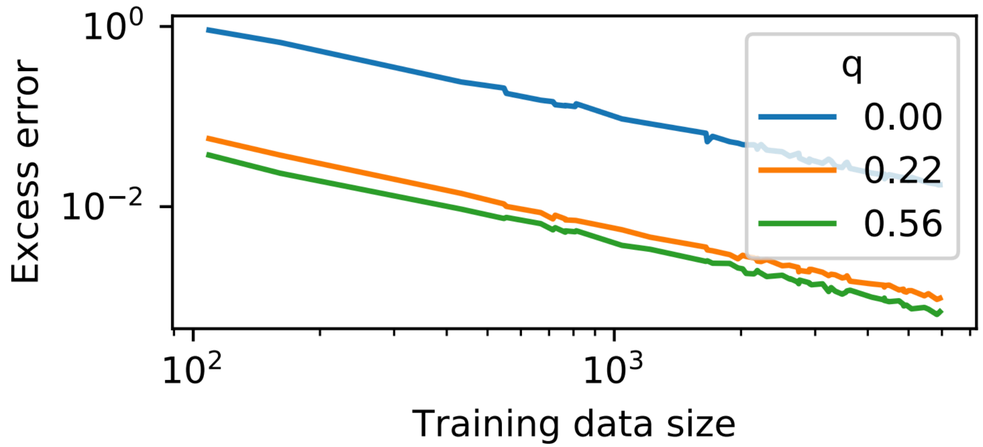
Поиск оптимальной смеси: Olmix

Design Choice	RegMix (Liu et al., 2025a)	DML (Ye et al., 2025)	AutoScale (Kang et al., 2025)	BiMix (Ge et al., 2025b)	ADMIRE-BayesOpt (Chen et al., 2025b)	CLIMB (Diao et al., 2025)	OLMIXBASE (Algorithm 1)
Swarm Construction							
Proxy model size	1M	70, 160, 305, 410M	Target	280M	1M, 60M	350M	30M
Swarm size (vs m domains)	512 ($m = 17$)	20 ($m = 7$)	$2m + 1$	4	101 ($m = 17$)	112 ($m = 21$)	$3(m + 1)$
Swarm distribution	Dirichlet with natural prior	Exponential grid	Exponential grid	Entropy-weighted	Dynamic	Dirichlet with natural prior	Dirichlet with natural prior (sparse for topics, dense for sources)
Regression Model							
Regression model family	LightGBM	Log-Linear	Power Law	Power Law	Gaussian Process	LightGBM	Log-Linear
Regression granularity	Aggregated	Aggregated	Per-Task	Per-Task	Aggregated	Aggregated	Per-Task
Mixture Optimization							
Data repetition constraints	No	No	No	No	No	No	Yes
Optimization solver	Search	Search	Gradient Descent	Exact Solver	Search	Search	Exact Solver with KL reg.

[Chen et al, 2026]

Закон для смеси данных

- Наклон не меняется; только сдвиг.
- Можно не обучать модели разного размера.



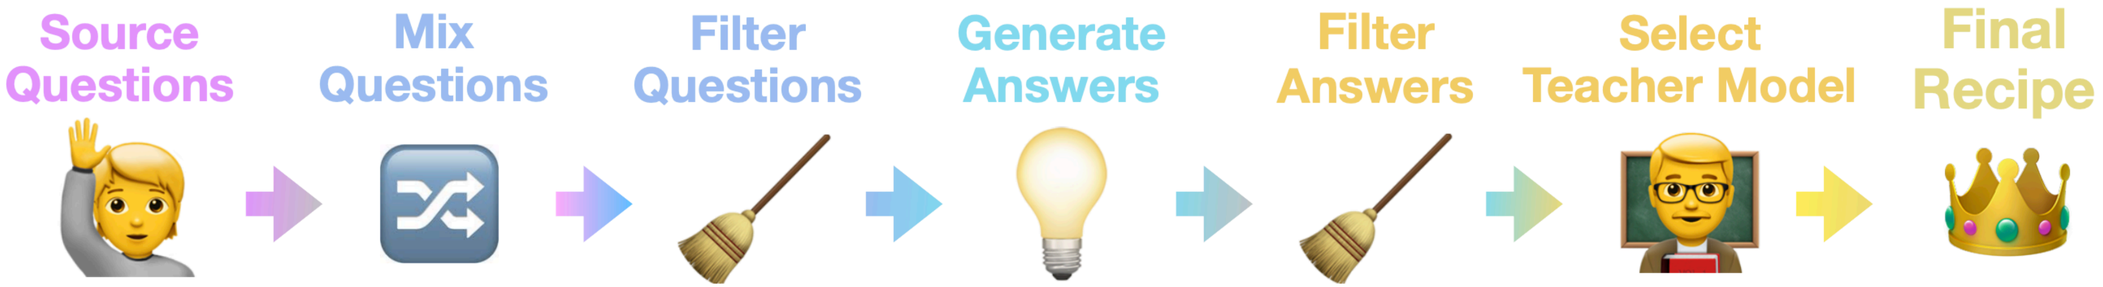
[Hashimoto, 2021]

Post-training data

Общий подход:

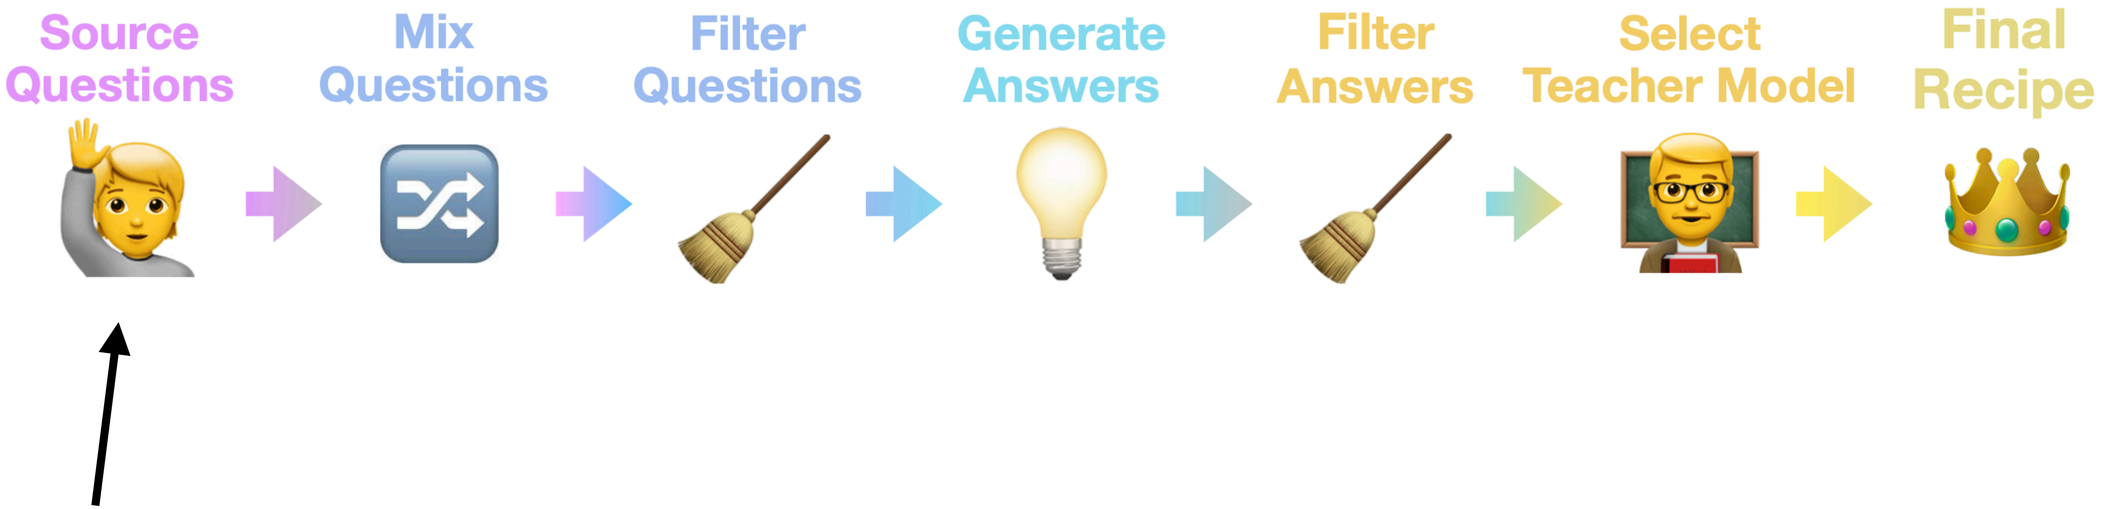
1. Собрать набор задач/промптов
2. Собрать ответы с помощью сильной модели (учителя)

OpenThoughts: математика и наука



[Guha et al, 2025]

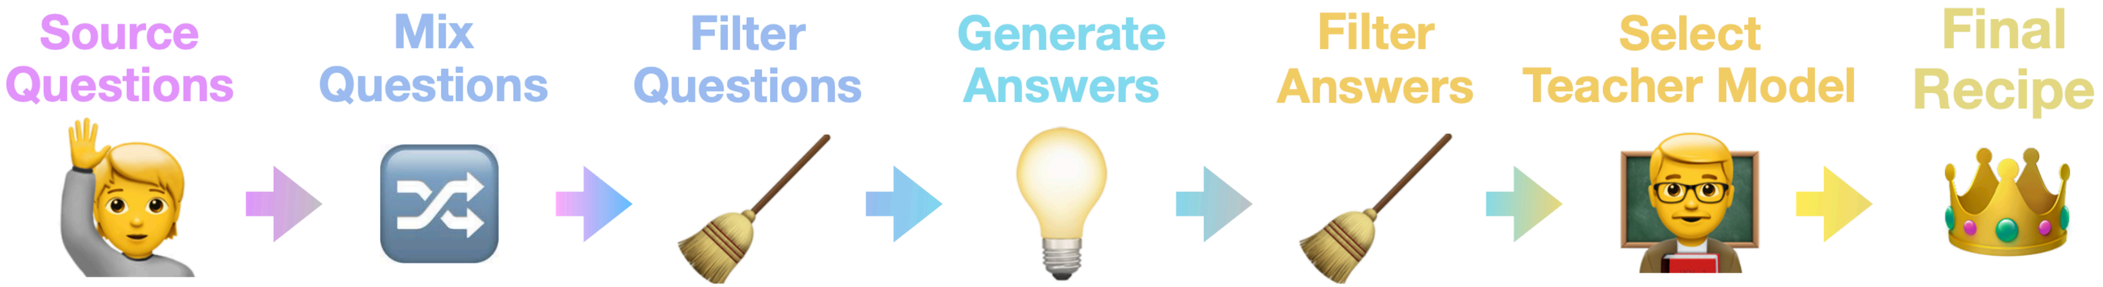
OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

[Guha et al, 2025]

OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

Лучше брать меньше источников, но лучшего качества

[Guha et al, 2025]

OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

Наиболее сложные вопросы для кода. Наиболее длинные ответы для математики.

Лучше брать меньше источников, но лучшего качества

[Guha et al, 2025]

OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

Лучше брать меньше источников, но лучшего качества

Наиболее сложные вопросы для кода. Наиболее длинные ответы для математики.

16 ответов для каждого запроса

[Guha et al, 2025]

OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

Лучше брать меньше источников, но лучшего качества

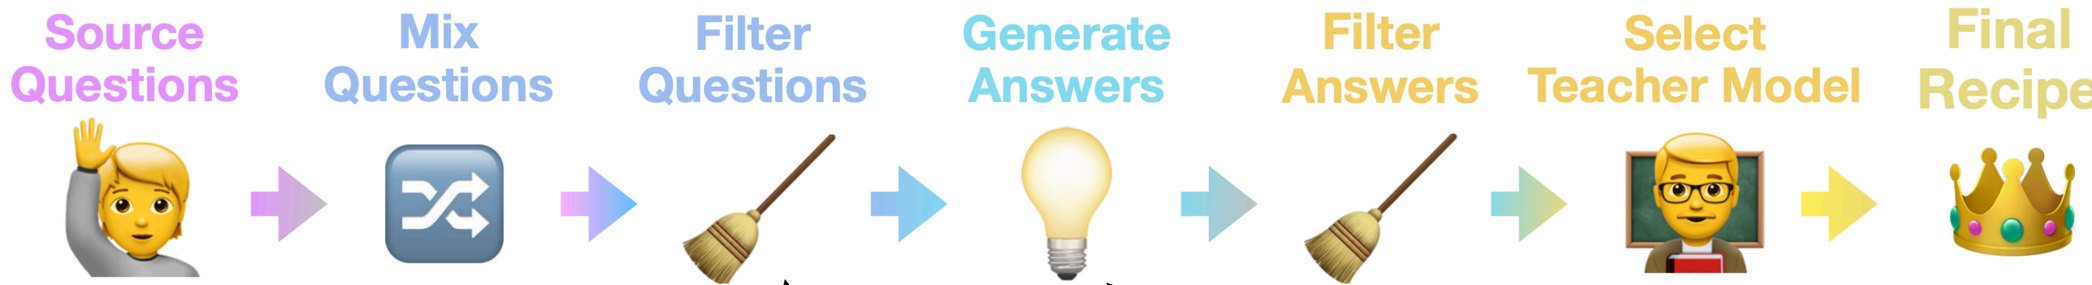
Наиболее сложные вопросы для кода. Наиболее длинные ответы для математики.

16 ответов для каждого запроса

Без фильтров #NoFilter

[Guha et al, 2025]

OpenThoughts: математика и наука



Смесь синтетических и натуральных данных

Лучше брать меньше источников, но лучшего качества

Наиболее сложные вопросы для кода. Наиболее длинные ответы для математики.

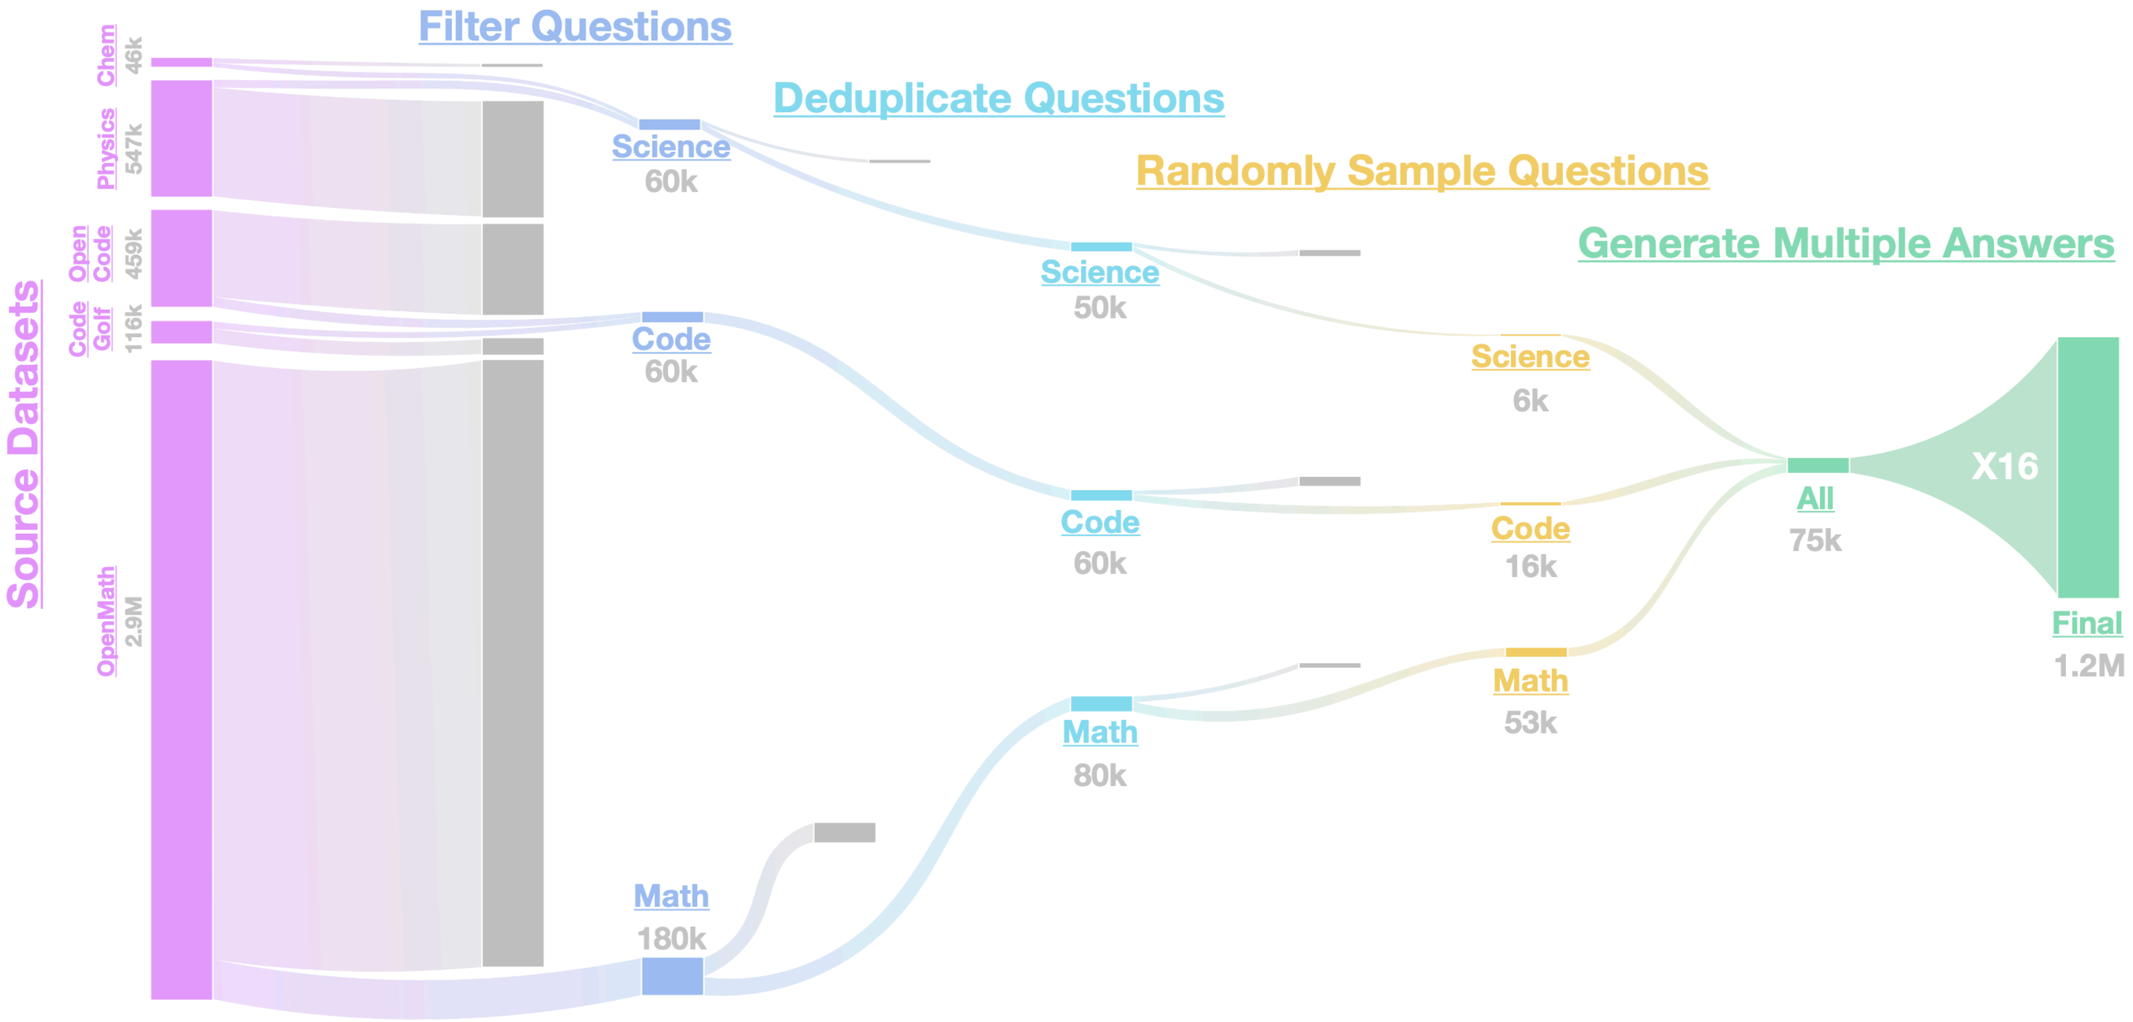
16 ответов для каждого запроса

Без фильтров #NoFilter

QwQ-32B > DeepSeek R1

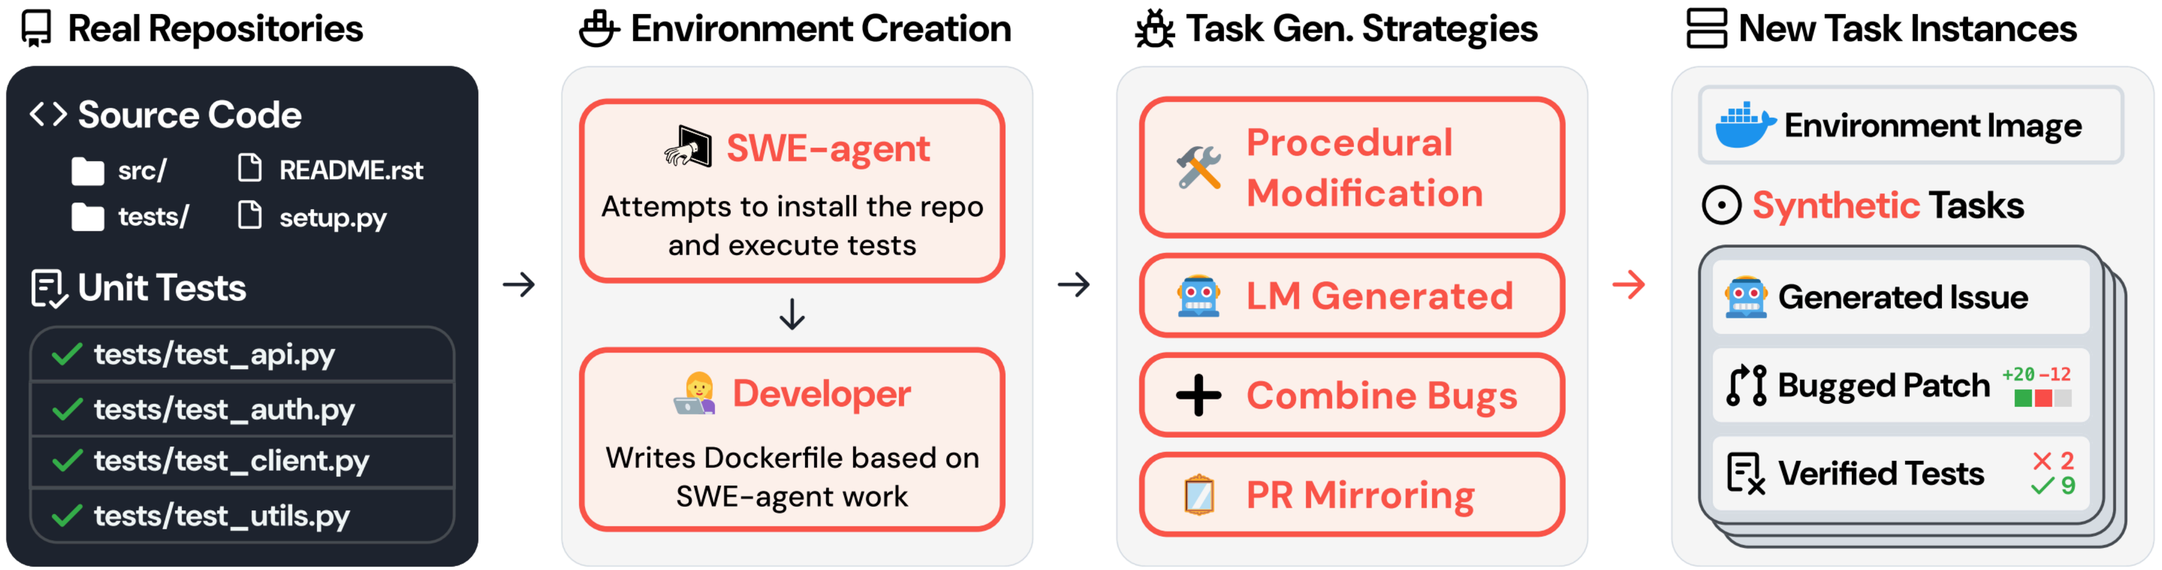
[Guha et al, 2025]

OpenThoughts: математика и наука



[Guha et al, 2025]

SWE-smith: код



1. Данные берутся из 128 самых качественных репозиториев
2. 5к самых популярных библиотек
3. Агент создает окружение
4. В код автоматически добавляются баги
5. Получаются 50к задач
6. На вход агенту дается окружение, описание проблемы и тест, который надо пройти

[Yang et al, 2025]

SWE-Zero to SWE-Hero

Наблюдение:
Мощным моделям не требуется доступ к запуску кода для решения задач.

Model	Execution	SWE-bench (V)	SWE-bench (M)
MiniMax-M2.5	×	69.5	57.2
	✓	80.2	74.1
Qwen3-Coder-Next	×	56.9	50.7
	✓	71.3	64.3
Qwen3-Coder-480B-A35B-Instruct	×	59.4	44.3
	✓	69.6	54.7
SWE-HERO-32B (Ours)	×	57.7	42.2
	✓	62.2	44.1

В таком случае можно не тратить силы на создание корректных окружений
Плюс появляется возможность использовать репозитории без корректных окружений

[Ludwig et al, 2025]

SWE-Zero to SWE-Hero

SWE-Zero

- 300к агентских траекторий без запуска кода.

SWE-Hero

- 13к траекторий, требующих запуск кода

Standard OpenHands Setup (Execution-Based)

System: You are OpenHands agent, a helpful AI assistant that can interact with a computer to solve tasks. The development Python environment is already set up for you.

Problem Solving Workflow:

- **Exploration:** Thoroughly explore relevant files and context.
- **Analysis:** Consider multiple approaches and select the most promising one.
- **Testing:** Create tests to verify issues; delete temporary files after confirmation.
- **Implementation:** Make focused, minimal changes to address the problem.
- **Verification:** Thoroughly test implementation, including edge cases.

User Instruction Phases:
Phase 1: Reading → Phase 2: Running → Phase 3: Exploration → Phase 4: Test Creation → Phase 5: Fix Analysis → Phase 6: Implementation → Phase 7: Verification → Phase 8: Final Review.

SWE-Zero OpenHands Setup (Execution-Free)

System: You are OpenHands agent... The development environment is **unavailable**. You **CANNOT RUN PYTHON CODE** for any purpose. Do not use Python to check your work.

Problem Solving Workflow:

- **Exploration:** Thoroughly explore files and understand context.
- **Analysis:** Consider multiple approaches (Static Analysis).
- **Implementation:** Make focused, minimal changes. **Do not write or execute any tests.**

Prohibited Bash Commands:
`python` (including `-c/-m` options), `pytest`, `mypy`, `pip`, `apt`, `apt-get`.

User Instruction Phases:
Phase 1: Reading → Phase 2: Exploration → Phase 3: Fix Analysis → Phase 4: Implementation → Phase 5: Final Review.

[Ludwig et al, 2025]