


Text diffusion models

Диффузионные модели

- Хотим получить генеративную модель для семплирования из $p(x)$.
- Зададим прямой процесс зашумления и будем учиться его обращать.



Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1}$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$\begin{aligned} x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\varepsilon_{t-2}) + \sqrt{1 - \alpha_t}\varepsilon_{t-1} \end{aligned}$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$\begin{aligned} x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\varepsilon_{t-2}) + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + (\sqrt{\alpha_t(1 - \alpha_{t-1})}\varepsilon_{t-2} + \sqrt{1 - \alpha_t}\varepsilon_{t-1}) \end{aligned}$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$\begin{aligned} x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\varepsilon_{t-2}) + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \underbrace{(\sqrt{\alpha_t(1 - \alpha_{t-1})}\varepsilon_{t-2})}_{\mathcal{N}(0, \alpha_t(1 - \alpha_{t-1})I)} + \underbrace{\sqrt{1 - \alpha_t}\varepsilon_{t-1}}_{\mathcal{N}(0, (1 - \alpha_t)I)} \end{aligned}$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$\begin{aligned} x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\varepsilon_{t-2}) + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \underbrace{(\sqrt{\alpha_t(1 - \alpha_{t-1})}\varepsilon_{t-2})}_{\mathcal{N}(0, \alpha_t(1 - \alpha_{t-1})I)} + \underbrace{\sqrt{1 - \alpha_t}\varepsilon_{t-1}}_{\mathcal{N}(0, (1 - \alpha_t)I)} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_t\alpha_{t-1}}\varepsilon \end{aligned}$$

Вывод алгоритма

Прямой процесс:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t|\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I), \quad \alpha_t \in [0, 1]$$

Нам пригодится $q(x_t|x_0)$, поэтому выведем ее.

$$\begin{aligned} x_t &= \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t}(\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_{t-1}}\varepsilon_{t-2}) + \sqrt{1 - \alpha_t}\varepsilon_{t-1} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \underbrace{(\sqrt{\alpha_t(1 - \alpha_{t-1})}\varepsilon_{t-2})}_{\mathcal{N}(0, \alpha_t(1 - \alpha_{t-1})I)} + \underbrace{\sqrt{1 - \alpha_t}\varepsilon_{t-1}}_{\mathcal{N}(0, (1 - \alpha_t)I)} = \\ &= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{1 - \alpha_t\alpha_{t-1}}\varepsilon = \dots = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\varepsilon \end{aligned}$$

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$

Вывод алгоритма

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon \Rightarrow \underline{q(x_t | x_0) = \mathcal{N}(x_t | \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)}$$

Вывод алгоритма

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon \Rightarrow \underline{q(x_t | x_0) = \mathcal{N}(x_t | \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)}$$

Обратный процесс:

$$p(x_{t-1} | x_t) = \mathcal{N}(x_{t-1} | \mu(x_t, t), \Sigma(x_t, t))$$

Мы не знаем $\mu(x_t, t)$ и $\Sigma(x_t, t)$ так как не знаем распределение $p(x)$.

Вывод алгоритма

$$\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$$

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\varepsilon \Rightarrow \underline{q(x_t|x_0) = \mathcal{N}(x_t|\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)}$$

Обратный процесс:

$$p(x_{t-1}|x_t) = \mathcal{N}(x_t|\mu(x_t, t), \Sigma(x_t, t))$$

Мы не знаем $\mu(x_t, t)$ и $\Sigma(x_t, t)$ так как не знаем распределение $p(x)$.

Вместо этого найдем $p(x_{t-1}|x_t, x_0)$

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_t|\tilde{\mu}(x_t, x_0), \tilde{\beta}_t I)$$

Вывод алгоритма

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_t|\tilde{\mu}(x_t, x_0), \tilde{\beta}_t I)$$

Вывод алгоритма

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_t|\tilde{\mu}(x_t, x_0), \tilde{\beta}_t I) = \frac{p(x_t|x_{t-1}, x_0)p(x_{t-1}|x_0)}{p(x_t|x_0)}$$

Вывод алгоритма

$$\mathcal{N}(x \mid \mu, \sigma) = \frac{1}{Z} \exp \left(- \frac{(x - \mu)^2}{2\sigma} \right)$$

$$\mathcal{N}(x_t \mid \sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I) \quad \mathcal{N}(x_{t-1} \mid \sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1})I)$$

$$\Downarrow$$
$$\Downarrow$$

$$p(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_t \mid \tilde{\mu}(x_t, x_0), \tilde{\beta}_t I) = \frac{p(x_t \mid x_{t-1}, x_0) p(x_{t-1} \mid x_0)}{p(x_t \mid x_0)}$$

$$\Downarrow$$

$$\mathcal{N}(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

Вывод алгоритма

$$\mathcal{N}(x \mid \mu, \sigma) = \frac{1}{Z} \exp \left(- \frac{(x - \mu)^2}{2\sigma} \right)$$

$$\mathcal{N}(x_t \mid \sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I) \quad \mathcal{N}(x_{t-1} \mid \sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1})I)$$

$$\parallel$$
$$\parallel$$

$$p(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_t \mid \tilde{\mu}(x_t, x_0), \tilde{\beta}_t I) = \frac{p(x_t \mid x_{t-1}, x_0) p(x_{t-1} \mid x_0)}{p(x_t \mid x_0)} \propto$$

$$\parallel$$

$$\mathcal{N}(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

$$\propto \exp \left[- \frac{1}{2} \left(\frac{(x_t - \sqrt{\alpha_t} x_{t-1})^2}{1 - \alpha_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right) \right] =$$

Вывод алгоритма

$$\mathcal{N}(x \mid \mu, \sigma) = \frac{1}{Z} \exp \left(- \frac{(x - \mu)^2}{2\sigma} \right)$$

$$\mathcal{N}(x_t \mid \sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I) \quad \mathcal{N}(x_{t-1} \mid \sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1})I)$$

$\parallel$

$\parallel$

$$p(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_t \mid \tilde{\mu}(x_t, x_0), \tilde{\beta}_t I) = \frac{p(x_t \mid x_{t-1}, x_0) p(x_{t-1} \mid x_0)}{p(x_t \mid x_0)} \propto$$

$\parallel$

$$\mathcal{N}(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

$$\propto \exp \left[- \frac{1}{2} \left(\frac{(x_t - \sqrt{\alpha_t} x_{t-1})^2}{1 - \alpha_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right) \right] =$$

$$= \exp \left[- \frac{1}{2} \left(\left(\frac{\alpha_t}{1 - \alpha_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) x_{t-1}^2 - 2 \left(\frac{\sqrt{\alpha_t}}{1 - \alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) x_{t-1} + C(x_t, x_0) \right) \right]$$

Вывод алгоритма

$$\mathcal{N}(x \mid \mu, \sigma) = \frac{1}{Z} \exp \left(- \frac{(x - \mu)^2}{2\sigma} \right)$$

$$\mathcal{N}(x_t \mid \sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t)I) \quad \mathcal{N}(x_{t-1} \mid \sqrt{\bar{\alpha}_{t-1}} x_0, (1 - \bar{\alpha}_{t-1})I)$$

$$\Downarrow$$

$$\Downarrow$$

$$p(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_t \mid \tilde{\mu}(x_t, x_0), \tilde{\beta}_t I) = \frac{p(x_t \mid x_{t-1}, x_0) p(x_{t-1} \mid x_0)}{p(x_t \mid x_0)} \propto$$

$$\Downarrow$$

$$\mathcal{N}(x_t \mid \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

$$\propto \exp \left[- \frac{1}{2} \left(\frac{(x_t - \sqrt{\alpha_t} x_{t-1})^2}{1 - \alpha_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right) \right] =$$

$$= \exp \left[- \frac{1}{2} \left(\left(\frac{\alpha_t}{1 - \alpha_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) x_{t-1}^2 - 2 \left(\frac{\sqrt{\alpha_t}}{1 - \alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) x_{t-1} + C(x_t, x_0) \right) \right]$$

$$\tilde{\beta}_t = \frac{1}{\frac{\alpha_t}{1 - \alpha_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}}$$

$$\tilde{\mu}(x_t, x_0) = \left(\frac{\sqrt{\alpha_t}}{1 - \alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) \tilde{\beta}_t$$

Вывод алгоритма

$$\tilde{\beta}_t = \frac{1}{\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}}$$

$$\tilde{\mu}(x_t, x_0) = \left(\frac{\sqrt{\alpha_t}}{1-\alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} x_0 \right) \tilde{\beta}_t$$

Вывод алгоритма

$$\tilde{\beta}_t = \frac{1}{\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{\alpha_t(1-\bar{\alpha}_{t-1}) + 1-\alpha_t} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

$$\tilde{\mu}(x_t, x_0) = \left(\frac{\sqrt{\alpha_t}}{1-\alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} x_0 \right) \tilde{\beta}_t$$

Вывод алгоритма

$$\tilde{\beta}_t = \frac{1}{\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{\alpha_t(1-\bar{\alpha}_{t-1}) + 1-\alpha_t} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

$$\begin{aligned}\tilde{\mu}(x_t, x_0) &= \left(\frac{\sqrt{\alpha_t}}{1-\alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} x_0 \right) \tilde{\beta}_t = \\ &= \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)}{1-\bar{\alpha}_t} x_0 =\end{aligned}$$

Вывод алгоритма

$$\tilde{\beta}_t = \frac{1}{\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{\alpha_t(1-\bar{\alpha}_{t-1}) + 1-\alpha_t} = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}$$

$$\begin{aligned}\tilde{\mu}(x_t, x_0) &= \left(\frac{\sqrt{\alpha_t}}{1-\alpha_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} x_0 \right) \tilde{\beta}_t = \\ &= \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)}{1-\bar{\alpha}_t} x_0 = \\ &\quad \left[x_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t} \varepsilon_t}{\sqrt{\bar{\alpha}_t}} \right] \\ &= \frac{1}{\bar{\alpha}_t} \left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \varepsilon_t \right)\end{aligned}$$

Почти готово

Что теперь?

Почти готово

Что теперь?

У нас есть явная формула для прямого процесса

$$q(x_t|x_0) = \mathcal{N}(x_t|\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

И для обратного

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_t|\tilde{\mu}(x_t, x_0), \tilde{\beta}_t I)$$

Почти готово

Что теперь?

У нас есть явная формула для прямого процесса

$$q(x_t|x_0) = \mathcal{N}(x_t|\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

И для обратного

$$p(x_{t-1}|x_t, x_0) = \mathcal{N}(x_t|\tilde{\mu}(x_t, x_0), \tilde{\beta}_t I)$$

$\tilde{\mu}(x_t, x_0)$ мы не знаем, поэтому обучим нейронную сеть для аппроксимации.

$$L_t = \|\tilde{\mu}(x_t, x_0) - \tilde{\mu}_\theta(x_t, t)\|^2 \quad \text{или} \quad L_t = \|\varepsilon_t - \varepsilon_\theta(x_t, t)\|^2$$


Обучение и инференс

Algorithm 1 Training

```
1: repeat  
2:    $\mathbf{x}_0 \sim q(\mathbf{x}_0)$   
3:    $t \sim \text{Uniform}(\{1, \dots, T\})$   
4:    $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$   
5:   Take gradient descent step on  
        $\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2$   
6: until converged
```

Algorithm 2 Sampling

```
1:  $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$   
2: for  $t = T, \dots, 1$  do  
3:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$   
4:    $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$   
5: end for  
6: return  $\mathbf{x}_0$ 
```



Text diffusion models

Зачем нужна текстовая диффузия?

- Авторегрессионные модели генерируют каждый токен отдельно. Это медленно.
- Авторегрессионные модели не могут исправлять свои ошибки.
- Люди не генерируют текст слева направо

Особенности текстовой диффузии

- Тексты имеют дискретную структуру => недифференцируемы
- Непонятно, как зашумлять текст

Два вида текстовых диффузий

- **Дискретные**
С дискретным шумом
- **Непрерывные**
С гауссовским шумом

Дискретный шум

- Можно смотреть на каждый токен, как на семпл из категориального распределения всех возможных токенов.
- В точке x_0 распределение вырожденное.
- $\mathbf{x}_T \sim \text{Cat}(\boldsymbol{\pi})$ – априорное распределение

$$q(\mathbf{z}_t | \mathbf{x}) = \text{Cat}(\mathbf{z}_t; \alpha_t \mathbf{x} + (1 - \alpha_t) \boldsymbol{\pi})$$

$$q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x}) = \text{Cat} \left(\mathbf{z}_s; \frac{[\alpha_{t|s} \mathbf{z}_t + (1 - \alpha_{t|s}) \mathbf{1} \boldsymbol{\pi}^\top \mathbf{z}_t] \odot [\alpha_s \mathbf{x} + (1 - \alpha_s) \boldsymbol{\pi}]}{\alpha_t \mathbf{z}_t^\top \mathbf{x} + (1 - \alpha_t) \mathbf{z}_t^\top \boldsymbol{\pi}} \right)$$

Multinomial Diffusion

Постепенно сводит распределение данных к **равномерному**.

$$q(x_t|x_{t-1}) = \mathcal{C}(x_t|\alpha_t x_{t-1} + (1 - \alpha_t)/K)$$

$$q(x_t|x_0) = \mathcal{C}(x_t|\bar{\alpha}_t x_{t-1} + (1 - \bar{\alpha}_t)/K)$$

$$p(x_{t-1}|x_t, x_0) = \mathcal{C}(x_{t-1}|D_{\text{post}}(x_t, x_0))$$


$$D_{\text{post}}(x_t, x_0) = \frac{1}{Z} [\alpha_t x_t + (1 - \alpha_t)/K] \odot [\bar{\alpha}_{t-1} x_0 + (1 - \bar{\alpha}_{t-1})/K]$$

T = 0	The great brown fox hopped over the lazy dog.
T = 10	The vast black fox hopping over the lazy cat.
T = 20	Their vast tripped this jumping upon walked organizations.
T = 25	Bunk scamper tripped this Sanchez walked organizations.

D3PM

Discrete Denoising Diffusion Probabilistic Model

Пробуют разные способы зашумления и показывают, что маскированный лучше всего



Absorbing (masked) diffusion

All tokens are replaced with [MASK]

$$Q_t[i,j] = \begin{cases} 1, & i = j = m \\ 1 - \beta_t, & i = j \neq m \\ \beta_t, & i \neq m, j = m \end{cases}$$

T = 0	The great brown fox hopped over the lazy dog.
T = 10	The great [MASK] fox hopped over [MASK] lazy dog.
T = 20	The [MASK][MASK] [MASK] ship over [MASK] lazy the.
T = 25	[MASK] [MASK] [MASK] [MASK] [MASK] [MASK] [MASK] [MASK] [MASK]

Absorbing (masked) diffusion

π – вырожденное распределение с $p(x_T = \mathbf{m}) = 1$

$$\mathbb{E}_q \left[\underbrace{-\log p_\theta(\mathbf{x} | \mathbf{z}_{t(0)})}_{\mathcal{L}_{\text{recons}}} + \underbrace{\sum_{i=1}^T D_{\text{KL}}[q(\mathbf{z}_{s(i)} | \mathbf{z}_{t(i)}, \mathbf{x}) || p_\theta(\mathbf{z}_{s(i)} | \mathbf{z}_{t(i)})]}_{\mathcal{L}_{\text{diffusion}}} \right] + \underbrace{D_{\text{KL}}[q(\mathbf{z}_{t(T)} | \mathbf{x}) || p_\theta(\mathbf{z}_{t(T)})]}_{\mathcal{L}_{\text{prior}}}$$

Ошибка сложно считается

$$D_{\text{KL}}(q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x}) || p_\theta(\mathbf{z}_s | \mathbf{z}_t)) =$$

$$= \left[\frac{\alpha_s - \alpha_t}{1 - \alpha_t} \log \frac{\alpha_t \langle \mathbf{x}_\theta(\mathbf{z}_t, t), \mathbf{m} \rangle + (1 - \alpha_t)}{(1 - \alpha_t) \langle \mathbf{x}_\theta(\mathbf{z}_t, t), \mathbf{x} \rangle} + \frac{1 - \alpha_s}{1 - \alpha_t} \log \frac{(1 - \alpha_s)(\alpha_t \langle \mathbf{x}_\theta(\mathbf{z}_t, t), \mathbf{m} \rangle + (1 - \alpha_t))}{(1 - \alpha_t)(\alpha_s \langle \mathbf{x}_\theta(\mathbf{z}_t, t), \mathbf{m} \rangle + (1 - \alpha_s))} \right] \langle \mathbf{z}_t, \mathbf{m} \rangle$$

Substitution-based parameterization (SUBS)

Перепараметризация, позволяющая проще семплировать и считать ошибку

$$q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x}) = \text{Cat} \left(\mathbf{z}_s; \frac{[\alpha_{t|s} \mathbf{z}_t + (1 - \alpha_{t|s}) \mathbf{1} \boldsymbol{\pi}^\top \mathbf{z}_t] \odot [\alpha_s \mathbf{x} + (1 - \alpha_s) \boldsymbol{\pi}]}{\alpha_t \mathbf{z}_t^\top \mathbf{x} + (1 - \alpha_t) \mathbf{z}_t^\top \boldsymbol{\pi}} \right)$$

Демаскированные токены больше не маскируются

$$p_\theta(\mathbf{z}_s | \mathbf{z}_t) = q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x} = \mathbf{x}_\theta(\mathbf{z}_t, t)) = \begin{cases} \text{Cat}(\mathbf{z}_s; \mathbf{z}_t), & \mathbf{z}_t \neq \mathbf{m}, \\ \text{Cat} \left(\mathbf{z}_s; \frac{(1 - \alpha_s) \mathbf{m} + (\alpha_s - \alpha_t) \mathbf{x}_\theta(\mathbf{z}_t, t)}{1 - \alpha_t} \right). & \mathbf{z}_t = \mathbf{m}, \end{cases}$$

Substitution-based parameterization (SUBS)

Перепараметризация, позволяющая проще семплировать и считать ошибку

$$q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x}) = \text{Cat} \left(\mathbf{z}_s; \frac{[\alpha_{t|s} \mathbf{z}_t + (1 - \alpha_{t|s}) \mathbf{1} \boldsymbol{\pi}^\top \mathbf{z}_t] \odot [\alpha_s \mathbf{x} + (1 - \alpha_s) \boldsymbol{\pi}]}{\alpha_t \mathbf{z}_t^\top \mathbf{x} + (1 - \alpha_t) \mathbf{z}_t^\top \boldsymbol{\pi}} \right)$$

Демаскированные токены больше не маскируются

$$p_\theta(\mathbf{z}_s | \mathbf{z}_t) = q(\mathbf{z}_s | \mathbf{z}_t, \mathbf{x} = \mathbf{x}_\theta(\mathbf{z}_t, t)) = \begin{cases} \text{Cat}(\mathbf{z}_s; \mathbf{z}_t), & \mathbf{z}_t \neq \mathbf{m}, \\ \text{Cat} \left(\mathbf{z}_s; \frac{(1 - \alpha_s) \mathbf{m} + (\alpha_s - \alpha_t) \mathbf{x}_\theta(\mathbf{z}_t, t)}{1 - \alpha_t} \right), & \mathbf{z}_t = \mathbf{m}, \end{cases}$$

$$\langle \mathbf{x}_\theta(\mathbf{z}_t, t), \mathbf{m} \rangle = 0 \quad \Rightarrow \quad \mathcal{L}_{\text{diffusion}} = \sum_{i=1}^T \mathbb{E}_q \left[\frac{\alpha_{t(i)} - \alpha_{s(i)}}{1 - \alpha_{t(i)}} \log \langle \mathbf{x}_\theta(\mathbf{z}_{t(i)}), \mathbf{x} \rangle \right]$$

Проблема упрощения

Токены, сгенерированные в начале, часто не очень хороши

Machine learning are is a field to study of research in artificial intelligence during which and the development [...]

Republic of DeltaWorld of Warcraft has made some significant improvements to game it in their the most recent improvement update, the “Death in the Vengeance” change “End of the World” update.

Mexico City is the largest city in France Mexico. With an estimated population of 22,752,000 22,000,000 [...]

Suppose Alice has 5 apples. If Alice gives 2 all of her the apples to Bob, she is left with zero apples.

Ремаскирование засшумленных токенов

GIDD



Generalized Interpolating
Discrete Diffusion

Смешивает равномерное и
маскирующее распределение

Это позволяет корректировать ошибки у полностью сгенерированных текстов

$$\alpha_t = \frac{1-t}{C_t}, \quad \beta_t \boldsymbol{\pi}_t = \frac{t}{C_t} \mathbf{m} + \frac{c_t}{C_t} \mathbf{u},$$

$$c_t = Bt^{\frac{\gamma}{2}}(1-t)^{\frac{\gamma}{2}}, \quad C_t = 1 + c_t$$



Ремаскирование засшумленных токенов

ReMDM

Позволяет маскировать уже демаскированные токены

$$q_{\sigma}(\mathbf{z}_s \mid \mathbf{z}_t, \mathbf{x}) = \begin{cases} \text{Cat}(\mathbf{z}_s; (1 - \sigma_t)\mathbf{x} + \sigma_t \mathbf{m}), & \mathbf{z}_t \neq \mathbf{m} \\ \text{Cat}(\mathbf{z}_s; \frac{\alpha_s - (1 - \sigma_t)\alpha_t}{1 - \alpha_t}\mathbf{x} + \frac{1 - \alpha_s - \sigma_t\alpha_t}{1 - \alpha_t}\mathbf{m}), & \mathbf{z}_t = \mathbf{m} \end{cases}$$

Ремаскирование засшумленных токенов

ReMDM

Позволяет маскировать уже демаскированные токены

$$q_{\sigma}(\mathbf{z}_s \mid \mathbf{z}_t, \mathbf{x}) = \begin{cases} \text{Cat}(\mathbf{z}_s; (1 - \sigma_t)\mathbf{x} + \sigma_t \mathbf{m}), & \mathbf{z}_t \neq \mathbf{m} \\ \text{Cat}(\mathbf{z}_s; \frac{\alpha_s - (1 - \sigma_t)\alpha_t}{1 - \alpha_t}\mathbf{x} + \frac{1 - \alpha_s - \sigma_t\alpha_t}{1 - \alpha_t}\mathbf{m}), & \mathbf{z}_t = \mathbf{m} \end{cases}$$


Method	MAUVE (↑)			Gen PPL. (↓)			Entropy (↑)		
Data	1.00			14.8			5.44		
AR ($T=1024$) [†]	0.760			12.1			5.22		
	$T=1024$	$T=2048$	$T=4096$	$T=1024$	$T=2048$	$T=4096$	$T=1024$	$T=2048$	$T=4096$
SEDD (absorb)	0.008	0.008	0.009	104.7	103.2	102.5	5.62	5.61	5.61
MDLM [†]	0.042	0.037	0.035	51.3	51.3	50.9	5.46	5.46	5.45
MDLM+FB [†]	0.133	0.197	0.243	33.8	28.6	22.8	5.35	5.28	5.18
MDLM+DFM [†]	0.254	0.294	0.269	21.7	21.0	20.7	5.20	5.19	5.17
ReMDM [†]	0.403	0.610	0.656	28.6	22.8	17.6	5.38	5.30	5.20

Непрерывный шум

- Токены переводятся в пространство эмбеддингов (или энкодингов)
- В этом пространстве учится гауссовская диффузия
- К выходам диффузии применяется декодер
- Работает намного лучше диффузии с дискретным шумом!

Diffusion-LM

- Первая подход к непрерывной текстовой диффузии.




$$\mathcal{L}_{\text{simple}}(\mathbf{x}_0) = \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_t | \mathbf{x}_0)} \|\mu_\theta(\mathbf{x}_t, t) - \hat{\mu}(\mathbf{x}_t, \mathbf{x}_0)\|^2.$$

$$\mathcal{L}_{\text{simple}}^{\text{e2e}}(\mathbf{w}) = \mathbb{E}_{q_\phi(\mathbf{x}_{0:T} | \mathbf{w})} [\mathcal{L}_{\text{simple}}(\mathbf{x}_0) + \|\text{EMB}(\mathbf{w}) - \mu_\theta(\mathbf{x}_1, 1)\|^2 - \log p_\theta(\mathbf{w} | \mathbf{x}_0)]$$

PLANNER


- VAE + autoregressive decoder



LD4LG

Latent Diffusion for Language Generation

- Latent space + autoregressive decoder




Трюки для текстовой диффузии

Трюки для обучения

Предсказание x_0 вместо ε_t работает эффективнее для диффузии на дискретных данных.


Никто до конца не понимает, почему.

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon_t$$





Трюки для обучения

Диффузионные модели надо учить **долго**.
Даже когда лосс перестает уменьшаться.



Трюки для обучения

Лучше брать более агрессивное расписание зашумления.



Schedules	BLEU	
	$F = 1$	$F = 4$
<i>Linear</i> (Ho et al., 2020)	31.02	31.98
<i>Cosine</i> (Nichol & Dhariwal, 2021)	26.61	32.68
<i>Sqrt</i> (Li et al., 2022)	2.85	34.13
<i>EDM</i> (Karras et al., 2022)	29.16	30.09

Трюки для обучения

Нормализация энкодингов

- x_0 должен иметь единичную дисперсию.
- Нормировать лучше по всем признакам отдельно, так как они отличаются по норме.

Трюки для обучения

Clamping trick

Округление предсказанного $\hat{x}_0$ до ближайшего текста на каждом шаге.

$$\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}} \cdot \text{Clamp}(f_{\theta}(\mathbf{x}_t, t)) + \sqrt{1 - \bar{\alpha}}\epsilon$$

Архитектурные трюки: Encoder


Диффузия работает лучше, если латентное пространство более гладкое.

- Encodings > embeddings
- Encoder должен для "похожих" текстов получать похожие латенты
- Учить encoder вместе с диффузией – плохая идея


Архитектурные трюки: Decoder

- Диффузионная модель аппроксимирует распределение $p(x)$.
 - Качество аппроксимации падает с уменьшением числа шагов.
 - При декодировании латентов хочется нивелировать ошибки.
- ➡ Лучше брать сложный декодер (несколько слоев трансформера)

Архитектурные трюки: Self-condition




(a) Standard reverse diffusion steps.




(b) Self-Conditioning on the previous $\mathbf{x}_0$ estimate.


Архитектурные трюки: Self-condition




(a) Standard reverse diffusion steps.




(b) Self-Conditioning on the previous x_0 estimate.



(a) CIFAR-10, UINT8.



(b) CIFAR-10, UINT8 (RAND).



(c) IMAGENET 64×64 .