



Multimodal LLMs

Multimodal LLMs

Модель, которая может обрабатывать сразу несколько модальностей данных
Мы будем рассматривать только генерацию текста




Multimodal LLMs




Deep Fusion: Standard Cross-Attention

- Самый простой способ обуславливания
- Картинка кодируется энкодером и подается в LLM с помощью C-A




Flamingo



Flamingo


CLIP-like Vision Encoder: выходы последнего слоя вытягиваются в последовательность



```
def perceiver_resampler(  
    x_f, # The [T, S, d] visual features (T=time, S=space)  
    time_embeddings, # The [T, 1, d] time pos embeddings.  
    x, # R learned latents of shape [R, d]  
    num_layers, # Number of layers  
):  
    """The Perceiver Resampler model."""  
  
    # Add the time position embeddings and flatten.  
    x_f = x_f + time_embeddings  
    x_f = flatten(x_f) # [T, S, d] -> [T * S, d]  
    # Apply the Perceiver Resampler layers.  
    for i in range(num_layers):  
        # Attention.  
        x = x + attention_i(q=x, kv=concat([x_f, x]))  
        # Feed forward.  
        x = x + ffw_i(x)  
    return x
```

Flamingo

К cross-attention добавляется масштабирующий коэффициент




Другие модели

Большинство других моделей наследуются от Flamingo (OpenFlamingo)

- Otter – OpenFlamingo, дообученный на MIMIC-IT
- MultiModal-GPT – LoRA для OpenFlamingo
- Dolphins – instruction tuned OpenFlamingo

VL-T5

Обучают T5 модель с возможностью добавлять эмбединги картинок




RoI находятся с помощью Faster R-CNN

Эмбединги RoI извлекаются с помощью энкодера (напр. UNITER)


Deep Fusion: Custom Cross-Attention

LLM использует модифицированные C-A слои, чтобы лучше работать с картинками




CogVLM

LLM обучает матрицы Q, V, K отдельно для картинок и отдельно для текста




(a) The input of visual language model



(b) The visual expert built on the language model


LLaMA-Adapter

- Добавляют обучаемый пром프트 к последним L слоям декодера
- Чтобы пром프트 не разломал модель в начале обучения, к нему добавляется масштабирующий коэффициент (как у Flamingo)




LLaMA-Adapter

- CLIP кодирует разные масштабы картинок
- Полученные энкодинги прибавляются к промπτу на каждом слое




Early Fusion: Non-Tokenized

- Наиболее распространенный вид MLLM.
- (Почти) никак не модифицирует LLM. Иногда добавляется LoRA.




BLIP-2

Обучают Q-Former для извлечения картиночных эмбеддингов




BLIP-2

Выход Q-Former напрямую подается в LLM




LLaVa

- Картинки кодируются с помощью CLIP (выход последнего слоя)
- На первом этапе обучаются только проекции
- После модель учится целиком




Early Fusion: Tokenized

- Токенизатор – модель вида VQ-VAE
- Преимущество: теперь можно генерировать и картинки тоже (авторегрессионно)




LaVIT

Картиночный токенизатор обучается находить только самые полезные токены



(a) Dynamic Visual Tokenizer



(b) The Token Merger

Сравнение подходов

	Deep Fusion		Early Fusion	
	SCA	CCA	N-Tok	Tok
Сложность модели	😊	😞	😄	😊
Контроль модальности	😄	😄	😭	😭
Эффективность обучения	😞	😊	😄	😭
Масштабируемость	😭	😞	😄	😄
Добавление доп модальностей	😭	😞	😊	😊 / 😭

Общие проблемы MLLM на сегодня

- Работа с длинным контекстом
- Следование сложным инструкциям
- Кросс-модальный ризонинг
- Добавление новых модальностей
- Безопасность